

# Spis treści

<b>1</b>	<b>Rachunek prawdopodobieństwa</b>	<b>3</b>
1.1	Definicja przestrzeni probabilistycznej . . . . .	3
1.2	Prawdopodobieństwo warunkowe . . . . .	3
1.3	Zmienne losowe . . . . .	4
1.4	Rozkłady brzegowe . . . . .	5
1.5	Zmienne losowe niezależne . . . . .	5
1.6	Funkcja tworząca momenty . . . . .	5
1.7	Funkcja charakterystyczna . . . . .	5
1.8	Rozkłady warunkowe . . . . .	6
1.9	Transformacja zmiennych wielowymiarowych . . . . .	6
1.10	Macierz kowariancji . . . . .	6
1.11	Wielowymiarowy rozkład normalny . . . . .	7
1.12	Zbieżność w rachunku prawdopodobieństwa . . . . .	8
1.13	Rozkłady prawdopodobieństwa . . . . .	8
1.13.1	Rozkład Bernoulliego . . . . .	8
1.13.2	Rozkład dwumianowy . . . . .	8
1.13.3	Rozkład geometryczny . . . . .	9
1.13.4	Rozkład Poissona . . . . .	9
1.13.5	Rozkład jednostajny . . . . .	9
1.13.6	Rozkład wykładniczy . . . . .	10
1.13.7	Rozkład gamma . . . . .	10
1.14	Elementarz teorii informacji . . . . .	10
1.14.1	Definicja i własności entropii . . . . .	10
1.14.2	Entropia względna . . . . .	12
1.15	Wnioskowanie statystyczne . . . . .	13
1.16	Twierdzenie Gliwenki–Cantelliego . . . . .	14
1.17	Silne prawo wielkich liczb . . . . .	14
1.18	Centralne Twierdzenie Graniczne . . . . .	15
1.19	Estymatory punktowe MLE i MAP . . . . .	15
<b>2</b>	<b>Probabilistyczne uczenie maszynowe</b>	<b>17</b>
2.1	Wnioskowanie Bayesowskie . . . . .	17
2.2	Bayesowski wybór modeli . . . . .	18
2.3	Estymator jądrowy gęstości (KDE) . . . . .	19
2.4	Modele Gaussowskie . . . . .	19
2.5	Liniowe modele Gaussowskie . . . . .	20
2.6	Regresja liniowa . . . . .	21
2.7	Regularyzacja . . . . .	24
2.8	Procesy Gaussowskie . . . . .	24

2.9	Wieloklasowa regresja logistyczna . . . . .	28
2.10	Wnioskowanie metodami Monte Carlo . . . . .	31
2.10.1	Algorytm Importance Sampling (IS) . . . . .	32
2.10.2	Algorytm Metropolisa–Hastingsa . . . . .	33
<b>3</b>	<b>Sieci neuronowe</b>	<b>37</b>
3.1	Tensory . . . . .	37
3.2	Neuron . . . . .	38
3.3	Sieć MLP . . . . .	39
3.4	Wsteczna propagacja błędu . . . . .	41
3.5	Automatyczne różniczkowanie . . . . .	43
3.6	Metody optymalizacji numerycznej . . . . .	43
3.7	Regularyzacja i inicjalizacja . . . . .	44
3.8	Sieci konwolucyjne (CNN) . . . . .	46
3.9	Mechanizmy uwagi . . . . .	46
<b>4</b>	<b>Reinforcement learning i teoria optymalnego sterowania</b>	<b>46</b>

# 1 Rachunek prawdopodobieństwa

## 1.1 Definicja przestrzeni probabilistycznej

Rozkładem prawdopodobieństwa  $P$  w pewnym zbiorze zdarzeń elementarnych  $\Omega \neq \emptyset$  nazywamy odwzorowanie

$$P : \Sigma \mapsto [0; 1],$$

gdzie  $\Sigma$  jest rodziną podzbiorów  $\Omega$  (inaczej rodziną zdarzeń) taką, że

$$\Omega \in \Sigma, \quad A \in \Sigma \implies A' \in \Sigma, \quad \forall A_1, A_2, \dots \in \Sigma : \bigcup_i A_i \in \Sigma,$$

które spełnia:  $P(\Omega) = 1$  oraz dla dowolnych parami rozłącznych zdarzeń  $A_1, A_2, \dots \in \Sigma$  zachodzi

$$P\left(\bigcup_i A_i\right) = \sum_i P(A_i).$$

Trójkę  $(\Omega, \Sigma, P)$  nazywamy przestrzenią probabilistyczną. Z powyższej definicji wynikają znane własności prawdopodobieństwa tj.  $P(A') = 1 - P(A)$  oraz  $P(A \cup B) = P(A) + P(B) - P(A, B)$ .

## 1.2 Prawdopodobieństwo warunkowe

Definiujemy również prawdopodobieństwo warunkowe zdarzenia  $A$  pod warunkiem zdarzenia  $B$  o dodatnim prawdopodobieństwie

$$P(A | B) := \frac{P(A, B)}{P(B)}.$$

Na podstawie powyższej definicji definiujemy niezależność zdarzeń  $A, B$  jako własność  $P(A, B) = P(A)P(B)$ , co dla zdarzenia  $B$  o dodatnim prawdopodobieństwie jest równoważne z  $P(A | B) = P(A)$ . Ponadto jeśli zdarzenia  $A_1, A_2, \dots \in \Sigma$  są parami rozłączne i zachodzi  $\bigcup_i A_i = \Omega$  to dla dowolnego zdarzenia  $B \in \Sigma$  możemy zapisać

$$P(B) = \sum_i P(B | A_i)P(A_i).$$

Z definicji prawdopodobieństwa warunkowego trywialnie udowodnić twierdzenie Bayesa

$$P(A | B) = \frac{P(B | A)P(A)}{P(B)}.$$

### 1.3 Zmienne losowe

W uczeniu maszynowym będą interesować nas zmienne o wartościach w  $\mathbb{R}^n$ . Zmienne takie nazywamy zmiennymi losowymi wielowymiarowymi i definiujemy jako odwzorowania

$$X : \Omega \mapsto \mathbb{R}^n$$

takie, że dla każdego  $A \subseteq \mathbb{R}^n$  zbiór  $\{\omega \in \Omega \mid X(\omega) \in A\}$  należy do rodziny zdarzeń  $\Sigma$ . Przy takiej definicji prawdopodobieństwo, iż zmienna  $X$  ma wartość należącą do pewnego przedziału  $A$  wynosi

$$P(X \in A) = P(\{\omega \in \Omega \mid X(\omega) \in A\}).$$

Dowolny rozkład prawdopodobieństwa zmiennej losowej  $n$ -wymiarowej  $X = (X_1, X_2, \dots, X_n)$  jest wyznaczony jednoznacznie przez zadanie funkcji  $F(\mathbf{x}) : \mathbb{R}^n \mapsto [0; 1]$  zwanej dystrybuantą zdefiniowanej jako

$$F(\mathbf{x}) = F(x_1, \dots, x_n) := P(X_1 \leq x_1, \dots, X_n \leq x_n).$$

Zasadniczo będą nas interesować jednak dwa przypadki rozkładów prawdopodobieństwa zmiennych losowych: rozkłady dyskretne i rozkłady ciągłe. W przypadku rozkładu dyskretnego istnieje pewien przeliczalny zbiór  $S \subset \mathbb{R}^n$  taki, że  $P(X \in S) = 1$ . Rozkład ten jest zadany jednoznacznie przez podanie  $|S|$  liczb  $p_i > 0$  określających prawdopodobieństwa  $p_i = P(X = \mathbf{x}_i)$  dla wszystkich  $\mathbf{x}_i \in S$ . W przypadku rozkładu ciągłego istnieje z kolei funkcja  $p(\mathbf{x}) : \mathbb{R}^n \mapsto [0; \infty)$  taka, że

$$P(X_1 \in [a_1; b_1], \dots, X_n \in [a_n; b_n]) = \int_{a_1}^{b_1} \cdots \int_{a_n}^{b_n} p(\mathbf{x}) d^n \mathbf{x}.$$

Funkcje  $p(\mathbf{x})$  nazywamy gęstością prawdopodobieństwa. W obu przypadkach musi być spełniony warunek unormowania postaci odpowiednio

$$\sum_i p_i = 1, \quad \int_{\mathbb{R}^n} p(\mathbf{x}) d^n \mathbf{x} = 1.$$

Będziemy często wykorzystywać wartość oczekiwaną pewnej funkcji  $f(\mathbf{x})$  zmiennej losowej  $X$  zdefiniowaną odpowiednio dla rozkładu  $p$  – dyskretnego lub ciągłego jako

$$\mathbb{E}[f(\mathbf{x})] := \sum_{\mathbf{x}_i \in S} f(\mathbf{x}_i) p_i \cong \int_{\mathbb{R}^n} f(\mathbf{x}) p(\mathbf{x}) d^n \mathbf{x}.$$

Zauważmy przy tym, iż funkcja  $f(\mathbf{x})$  może być zupełnie dowolna, np. dla funkcji charakterystycznej (indykatorowej) zbioru  $A \subset \mathbb{R}^n$   $f(\mathbf{x}) = \mathcal{I}_A$  mamy  $\mathbb{E}[\mathcal{I}_A(\mathbf{x})] = P(X \in A)$  lub dla iloczynu funkcji Heaviside’a  $f(\mathbf{x}) = \theta(t_1 - x_1) \cdots \theta(t_n - x_n)$  mamy  $\mathbb{E}[f(\mathbf{x})] = F(t_1, \dots, t_n)$ .

## 1.4 Rozkłady brzegowe

Niech  $X = (X_1, \dots, X_n)$  będzie  $n$ -wymiarową zmienną losową o dystrybuancie  $F(\mathbf{x})$ . Rozkład brzegowy względem  $k$  zmiennych  $X_{\sigma(1)}, \dots, X_{\sigma(k)}$  definiujemy jako rozkład wyznaczony przez dystrybuantę

$$F_{X_{\sigma(1)}, \dots, X_{\sigma(k)}}(x_{\sigma(1)}, \dots, x_{\sigma(k)}) := \lim_{x_{\sigma(k+1)} \rightarrow \infty, \dots, x_{\sigma(n)} \rightarrow \infty} F(x_1, \dots, x_n).$$

## 1.5 Zmienne losowe niezależne

Niech  $X = (X_1, \dots, X_k)$  będzie  $n$ -wymiarową zmienną losową o rozkładzie wyznaczonym przez dystrybuantę  $F(\mathbf{x})$ . Powiemy, iż zmienne losowe  $n_1, \dots, n_k$  - wymiarowych ( $n_1 + \dots + n_k = n$ )  $X_1, \dots, X_k$  są niezależne iff dla dowolnych  $\mathbf{x}_1 \in \mathbb{R}^{n_1}, \dots, \mathbf{x}_k \in \mathbb{R}^{n_k}$  zachodzi

$$F(\mathbf{x}_1, \dots, \mathbf{x}_k) = F_{X_1}(\mathbf{x}_1) \cdot \dots \cdot F_{X_k}(\mathbf{x}_k).$$

## 1.6 Funkcja tworząca momenty

Funkcją tworzącą momenty (z ang. *moment generating function*) nazywamy funkcję określoną wzorem

$$M_X(t) := \mathbb{E}[e^{tX}]$$

dla zmiennej losowej rzeczywistej  $X : \Sigma \mapsto \mathbb{R}$ . Powyższa wielkość jest określona zawsze tylko dla  $t = 0$ . Dla innych  $t$ ,  $M_X(t)$  może w ogólności nie istnieć. MGF używamy, aby łatwiej obliczać momenty różnych rzędów. Istotnie jeśli  $M_X(t)$  istnieje w pewnym otoczeniu  $t = 0$  to

$$\mathbb{E}[X^k] = \left. \frac{d^k M_X}{dt^k} \right|_{t=0}.$$

Jednocześnie łatwo pokazać, że zachodzi  $M_X(at) = M_{aX}(t)$  oraz  $M_{X+b}(t) = M_X(t)e^{tb}$ .

## 1.7 Funkcja charakterystyczna

Funkcję charakterystyczną rozkładu o gęstości  $p(x)$  definiujemy jako

$$\varphi_X(x) = \mathbb{E}[e^{itx}] = \int_{-\infty}^{+\infty} p(x)e^{itx} dx.$$

Widzimy, iż jest to zatem transformata Fouriera funkcji gęstości. Funkcja charakterystyczna koduje pełną informację o rozkładzie i możemy wyciągnąć z niej funkcję gęstości przez zastosowanie odwrotnej transformacji Fouriera.

## 1.8 Rozkłady warunkowe

W ogólnym przypadku zmiennej losowej  $n$  – wymiarowej  $Z = (Z_1, \dots, Z_n)$  o ciągłym rozkładzie  $p(\mathbf{z})$  jeśli wydzielimy zmienne  $k$  i  $n - k$  – wymiarowe  $X = (Z_{\sigma(1)}, \dots, Z_{\sigma(k)})$ ,  $Y = (Z_{\sigma(k+1)}, \dots, Z_{\sigma(n)})$  to rozkład warunkowy zmiennej  $X \mid Y$  definiujemy jako rozkład zadany przez gęstość prawdopodobieństwa

$$p(\mathbf{x} \mid \mathbf{y}) := \frac{p(\mathbf{z})}{p_Y(\mathbf{y})} = \frac{p(\mathbf{x}, \mathbf{y})}{p_Y(\mathbf{y})}.$$

## 1.9 Transformacja zmiennych wielowymiarowych

Niech  $X = (X_1, \dots, X_n)$  będzie zmienną losową wielowymiarową o rozkładzie ciągłym o gęstości  $p_X(\mathbf{x})$ . Rozważmy bijekcję  $(X_1, \dots, X_n) \mapsto (Y_1, \dots, Y_n)$ . Chcemy znaleźć wyrażenie na gęstość  $p_Y(\mathbf{y})$  w nowych zmiennych. Ponieważ infinitezymalne prawdopodobieństwo jest niezmiennicze względem zmiany współrzędnych więc zachodzi

$$p_X(x_1, \dots, x_n) dx_1 \dots dx_n = p_Y(y_1, \dots, y_n) dy_1 \dots dy_n,$$

skąd

$$p_Y(y_1, \dots, y_n) = \left| \frac{\partial(x_1, \dots, x_n)}{\partial(y_1, \dots, y_n)} \right| p_X(x_1(\mathbf{y}), \dots, x_n(\mathbf{y})).$$

## 1.10 Macierz kowariancji

Macierz kowariancji funkcji  $f(\mathbf{x})$  zmiennej losowej  $X$  definiujemy jako

$$\mathbf{\Sigma}[f(\mathbf{x})] := \mathbb{E}[(f(\mathbf{x}) - \boldsymbol{\mu}_f)(f(\mathbf{x}) - \boldsymbol{\mu}_f)^\top],$$

gdzie  $\boldsymbol{\mu}_f = \mathbb{E}[f(\mathbf{x})]$ . Elementy diagonalne  $\Sigma_{ii}$  tej macierzy nazywamy wariancjami zmiennych  $X_i$ , natomiast elementy pozadiagonalne  $\Sigma_{ij}$  nazywamy kowariancjami zmiennych  $X_i$  i  $X_j$ . Oczywiście  $\mathbf{\Sigma}$  jest macierzą symetryczną. Nadto jeśli  $f$  jest funkcją identycznościową tj.  $f(\mathbf{x}) = \mathbf{x}$  to  $\mathbf{\Sigma}$  jest macierzą nieujemnie określoną, gdyż dla dowolnego  $\mathbf{v} \in \mathbb{R}^n$  mamy

$$\mathbf{v}^\top \mathbf{\Sigma} \mathbf{v} = \mathbb{E}[\mathbf{v}^\top (\mathbf{x} - \boldsymbol{\mu})(\mathbf{x} - \boldsymbol{\mu})^\top \mathbf{v}] = \mathbb{E}[z^2] \geq 0,$$

gdzie  $z = \mathbf{v}^\top (\mathbf{x} - \boldsymbol{\mu}) \in \mathbb{R}$ . Jeśli  $X_1, \dots, X_n$  są niezależne i  $f$  jest funkcją identycznościową to  $\mathbf{\Sigma}$  jest macierzą diagonalną.

## 1.11 Wielowymiarowy rozkład normalny

Jeśli zmienna wielowymiarowa  $X = (X_1, \dots, X_n)$  ma wielowymiarowy rozkład normalny (z ang. *Multivariate Normal distribution* – *MVN*) z wartością oczekiwaną  $\boldsymbol{\mu}$  i macierzą kowariancji  $\boldsymbol{\Sigma}$ , co oznaczamy jako  $X \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ , to gęstość prawdopodobieństwa jest dana

$$\phi(\mathbf{x}) = \frac{1}{\sqrt{(2\pi)^n \det \boldsymbol{\Sigma}}} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right\}$$

Macierz  $\boldsymbol{\Lambda} = \boldsymbol{\Sigma}^{-1}$  nazywamy macierzą precyzji. Jeśli  $\mathbf{v}_i$  są unormowanymi wektorami własnymi macierzy  $\boldsymbol{\Sigma}$ , a  $\lambda_i$  odpowiadającymi im wartościami własnymi i zakładając, iż widmo  $\{\lambda_i\}$  jest niezdegenerowane mamy z twierdzenia spektralnego

$$\boldsymbol{\Lambda} = \sum_{i=1}^n \frac{1}{\lambda_i} \mathbf{v}_i \mathbf{v}_i^\top$$

oraz wiemy, iż wektory  $\{\mathbf{v}_i\}$  tworzą bazę ortonormalną przestrzeni  $\mathbb{R}^n$ . Z powyższego możemy zatem wyrazić wektor  $\mathbf{x} - \boldsymbol{\mu}$  jako kombinację liniową wektorów  $\{\mathbf{v}_i\}$  tj.

$$\mathbf{x} - \boldsymbol{\mu} = \sum_{i=1}^n t_i \mathbf{v}_i,$$

co pozwala zapisać gęstość prawdopodobieństwa jako

$$\phi(t_1, \dots, t_n) \cong \exp \left\{ -\frac{1}{2} \sum_{i=1}^n \frac{t_i^2}{\lambda_i} \right\}.$$

Z powyższego wzoru widać, iż poziomice gęstości są wielowymiarowymi elipsoidami, których półosie są skierowane wzdłuż wektorów własnych  $\boldsymbol{\Sigma}$  i mają długości proporcjonalne do  $\sqrt{\lambda_i}$ .

Powiemy, iż wielowymiarowa zmienna losowa  $X \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$  ma standardowy wielowymiarowy rozkład normalny jeśli  $\boldsymbol{\mu} = \mathbf{0}$  i  $\boldsymbol{\Sigma} = \mathbf{1}$ . Wówczas

$$\phi(\mathbf{x}) = \frac{1}{\sqrt{(2\pi)^n}} \exp \left\{ -\frac{1}{2} \mathbf{x}^\top \mathbf{x} \right\}.$$

Można wykazać, iż jeśli  $X \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$  dla  $\boldsymbol{\Sigma}$  o niezdegenerowanym widmie to wszystkie rozkłady brzegowe i warunkowe  $X$  są rozkładami normalnymi.

## 1.12 Zbieżność w rachunku prawdopodobieństwa

W rachunku prawdopodobieństwa definiujemy trzy zasadnicze rodzaje zbieżności ciągu zmiennych losowych  $(X_n)$ .

- Ciąg  $(X_n)$  jest zbieżny do  $X$  stochastycznie iff

$$\forall \epsilon > 0 : \lim_{n \rightarrow \infty} P(|X_n - X| < \epsilon) = 1.$$

- Ciąg  $(X_n)$  jest zbieżny do  $X$  z prawdopodobieństwem 1 iff

$$P\left(\lim_{n \rightarrow \infty} X_n = X\right) = 1.$$

- Ciąg  $(X_n)$   $n$ -wymiarowych zmiennych losowych jest zbieżny do  $X$  według dystrybuant iff

$$\forall \mathbf{x} \in \mathbb{R}^n, F_X(\mathbf{x}) - \text{ciągła w } \mathbf{x} : \lim_{n \rightarrow \infty} F_{X_n}(\mathbf{x}) = F_X(\mathbf{x})$$

Pomiędzy tak zdefiniowanymi rodzajami zbieżności zachodzą następujące implikacje:

1.  $X_n \rightarrow X$  z prawdopodobieństwem 1  $\implies X_n \rightarrow X$  stochastycznie
2.  $X_n \rightarrow X$  stochastycznie  $\implies X_n \rightarrow X$  według dystrybuant
3.  $X_n \rightarrow X$  stochastycznie  $\implies$  istnieje podciąg  $(X_{n_k})$  zbieżny do  $X$  z prawdopodobieństwem 1

## 1.13 Rozkłady prawdopodobieństwa

### 1.13.1 Rozkład Bernoulliego

Jeśli zmienna losowa ma wartości w zbiorze  $\{x_1, x_2\}$  oraz  $P(X = x_1) = p$  i  $P(X = x_2) = 1 - p$  (dla  $0 \leq p \leq 1$ ) to mówimy, że  $X \sim \text{Ber}(p)$  (zmienna  $X$  ma rozkład Bernoulliego z parametrem  $p$ ).

### 1.13.2 Rozkład dwumianowy

Próba Bernoulliego nazywamy doświadczenie losowe, którego wynik  $X \sim \text{Ber}(p)$ . Schematem dwumianowym nazywamy  $n$ -krotne powtórzenie próby Bernoulliego przy założeniu, iż poszczególne próby są niezależne. Jeśli  $S$  będzie zmienną losową



o wartościach w  $\mathbb{N} \cup \{0\}$ , która opisuje liczbę sukcesów w schemacie dwumianowym długości  $n$ . Wówczas

$$P(S = k) = \binom{n}{k} p^k (1-p)^{n-k}$$

i mówimy, że  $S \sim \text{Bin}(n, p)$  (zmienna  $S$  ma rozkład dwumianowy z parametrami  $n, p$ ).

### 1.13.3 Rozkład geometryczny

Rozważamy schemat Bernoulliego o nieskończonej długości. Jeśli  $T$  będzie zmienną losową o wartościach w  $\mathbb{N} \cup \{0\}$ , która opisuje liczbę prób Bernoulliego z parametrem  $p$  do momentu uzyskania pierwszego sukcesu to

$$P(T = k) = (1-p)^{k-1} p$$

i mówimy, że  $T \sim \text{Geo}(p)$  (zmienna  $T$  ma rozkład geometryczny z parametrem  $p$ ).

### 1.13.4 Rozkład Poissona

Założmy, iż mamy dany skończony przedział czasowy  $[0; \tau]$  dla pewnego  $\tau$ . Niech zmienna losowa  $N$  o wartościach w  $\mathbb{N} \cup \{0\}$  opisuje liczbę wystąpień pewnego zdarzenia w tym przedziale, przy czym

- zdarzenia występują niezależnie od siebie
- intensywność wystąpień jest stała

to

$$P(N = k) = \frac{e^{-\lambda} \lambda^k}{k!}$$

i mówimy, że  $N \sim \text{Pois}(\lambda)$  (zmienna  $N$  ma rozkład Poissona z parametrem  $\lambda$ ). Zachodzi ponadto **twierdzenie Poissona**: niech  $(S_n)$  będzie ciągiem takim, że  $S_n \sim \text{Bin}(n, p_n)$ , gdzie ciąg  $(p_n)$  jest taki, iż  $\lim_{n \rightarrow \infty} np_n = \lambda$ , wówczas

$$\lim_{n \rightarrow \infty} P(S_n = k) = \frac{e^{-\lambda} \lambda^k}{k!}.$$

### 1.13.5 Rozkład jednostajny

Jeśli zmienna losowa  $X$  o wartościach rzeczywistych ma gęstość prawdopodobieństwa daną przez

$$p(x) = \begin{cases} \frac{1}{b-a}, & x \in [a; b] \\ 0, & x \notin [a; b] \end{cases}$$

to mówimy  $X \sim \mathcal{U}(a, b)$  (zmienna  $X$  ma rozkład jednostajny na odcinku  $[a; b]$ ).

### 1.13.6 Rozkład wykładniczy

Jeśli zmienna losowa  $T$  o wartościach rzeczywistych opisuje prawdopodobieństwo uzyskania pierwszego zdarzenia po czasie  $x$  modelowanego przez rozkład  $\text{Pois}(\lambda)$  to

$$p(x) = \begin{cases} \lambda e^{-\lambda x}, & x \geq 0 \\ 0, & x < 0 \end{cases}$$

i mówimy  $T \sim \text{Exp}(\lambda)$  (zmienna  $T$  ma rozkład wykładniczy z parametrem  $\lambda$ ).

### 1.13.7 Rozkład gamma

Mówimy, że zmienna  $X$  o wartościach rzeczywistych ma rozkład gamma z parametrami  $p, a > 0$  tj.  $X \sim \Gamma(p, a)$  iff gęstość prawdopodobieństwa ma postać

$$p(x) = \begin{cases} \frac{a^p}{\Gamma(p)} x^{p-1} e^{-ax}, & x > 0 \\ 0, & x \leq 0 \end{cases},$$

gdzie  $\Gamma$  to funkcja gamma Eulera. Parametr  $p$  nazywamy parametrem kształtu, a  $a$  – parametrem intensywności. Szczególnym przypadkiem rozkładu gamma jest rozkład  $\chi^2$  zdefiniowany jako rozkład  $\chi^2(n) := \Gamma(n/2, 1/2)$ .

## 1.14 Elementarz teorii informacji

### 1.14.1 Definicja i własności entropii

Mając dany skończony zbiór zdarzeń elementarnych  $\{A_1, \dots, A_n\}$  taki, że wynikiem eksperymentu losowego może być dokładnie jedno z nich oraz prawdopodobieństwa  $p_1, \dots, p_n$ ,  $\sum_i p_i = 1$  każdego z nich powiemy, iż

$$A := \begin{pmatrix} A_1 & A_2 & \cdots & A_n \\ p_1 & p_2 & \cdots & p_n \end{pmatrix}$$

jest *schematem skończonym* (z ang. *finite scheme*). Przykładowo rzut sprawiedliwą, sześcienną kostką do gry jest opisany przez schemat

$$\begin{pmatrix} A_1 & A_2 & A_3 & A_4 & A_5 & A_6 \\ 1/6 & 1/6 & 1/6 & 1/6 & 1/6 & 1/6 \end{pmatrix}.$$

Zauważmy, że każdy schemat skończony opisuje pewną *niepewność* dotyczącą doświadczenia losowego. Przykładowo jest oczywiste, iż dla schematów

$$\begin{pmatrix} A_1 & A_2 \\ 0.99 & 0.01 \end{pmatrix}, \quad \begin{pmatrix} A_1 & A_2 \\ 0.5 & 0.5 \end{pmatrix}$$

pierwszy z nich opisuje znacznie mniejszą niepewność od drugiego, gdyż prawie z pewnością wynikiem eksperymentu losowego będzie  $A_1$ . Wprowadzimy teraz wielkość, która w sensowny sposób mierzy ilość niepewności w danym schemacie skończonym. Wielkością taką jest *entropia Shannona* zdefiniowana dla schematu

$$A = \begin{pmatrix} A_1 & A_2 & \cdots & A_n \\ p_1 & p_2 & \cdots & p_n \end{pmatrix}$$

jako

$$H(A) = H(p_1, p_2, \dots, p_n) := - \sum_{i=1}^n p_i \lg p_i,$$

gdzie możemy wybrać dowolną ustaloną podstawę logarytmu oraz stwierdzamy, iż jeśli  $p_k = 0$  to  $p_k \lg p_k = 0$ . Jeśli jako podstawę wybierzemy liczbę 2 to entropię mierzymy w *bitach* tj. 1 bit jest to ilość niepewności zawarta w schemacie skończonym o dwóch jednakowo prawdopodobnych wynikach

$$H = -\log_2 \frac{1}{2} = 1.$$

Przekonamy się teraz, iż tak zdefiniowana miara niepewności ma szereg własności, których spodziewalibyśmy się dla sensownej miary niepewności. Zauważmy wpierw, iż  $H(p_1, \dots, p_n) = 0$  iff dokładnie jedno zdarzenie  $A_k \in A$  jest pewne, a pozostałe niemożliwe. Zauważmy dodatkowo, iż z nierówności Jensena mamy dla funkcji wypukłej  $\phi(x) = x \lg x$

$$\phi \left( \sum_{i=1}^n \lambda_i x_i \right) \leq \sum_{i=1}^n \lambda_i \phi(x_i),$$

dla dowolnych  $x_1, \dots, x_n \in \mathbb{R}$  i  $\lambda_1, \dots, \lambda_n \in [0; 1]$ ,  $\sum_i \lambda_i = 1$ , skąd

$$\frac{1}{n} \lg \frac{1}{n} \leq \frac{1}{n} \sum_{i=1}^n p_i \lg p_i = -\frac{1}{n} H(p_1, \dots, p_n),$$

czyli

$$H(p_1, \dots, p_n) \leq -\lg \frac{1}{n} = H(1/n, 1/n, \dots, 1/n),$$

czyli niepewność zawarta w danym schemacie skończonym jest mniejsza lub równa od niepewności zawartej w analogicznym schemacie, w którym wszystkie wyniki są jednakowo prawdopodobne.

Założmy teraz, że mamy dwa niezależne schematy skończone

$$A = \begin{pmatrix} A_1 & A_2 & \cdots & A_n \\ p_1 & p_2 & \cdots & p_n \end{pmatrix}, \quad B = \begin{pmatrix} B_1 & B_2 & \cdots & B_m \\ q_1 & q_2 & \cdots & q_m \end{pmatrix}$$

takie, że dla każdej pary zdarzeń  $A_i, B_j$  prawdopodobieństwo wystąpienia zdarzenia  $A_i B_j$  wynosi  $p_i q_j$ . Zbiór zdarzeń  $A_i B_j$  z prawdopodobieństwami  $r_{ij} = p_i q_j$  reprezentuje nowy schemat skończony  $AB$ . Wówczas

$$\begin{aligned} -H(AB) &= \sum_{i=1}^n \sum_{j=1}^m r_{ij} \lg r_{ij} = \sum_{i=1}^n \sum_{j=1}^m p_i q_j (\lg p_i + \lg q_j) \\ &= \sum_{i=1}^n p_i \lg p_i + \sum_{j=1}^m q_j \lg q_j = -H(A) - H(B), \end{aligned}$$

skąd

$$H(AB) = H(A) + H(B).$$

Rozważmy teraz przypadek gdy schematy  $A, B$  są zależne. Przez  $q_{ij}$  oznaczmy prawdopodobieństwo zajścia zdarzenia  $B_j$  pod warunkiem zdarzenia  $A_i$  tj.  $q_{ij} = p(B_j | A_i)$ . Schemat  $AB$  jest teraz opisany prawdopodobieństwami  $r_{ij} = p_i q_{ij}$  zatem

$$-H(AB) = \sum_{i=1}^n \sum_{j=1}^m p_i q_{ij} (\lg p_i + \lg q_{ij}) = -H(A) + \sum_{i=1}^n p_i \sum_{j=1}^m q_{ij} \lg q_{ij}$$

gdyż  $\sum_j q_{ij} = 1$  (prawdopodobieństwo zajścia dowolnego zdarzenia z  $B$  pod warunkiem wystąpienia zdarzenia  $A_i$  wynosi 1), natomiast wielkość  $-\sum_{j=1}^m q_{ij} \lg q_{ij}$  jest warunkową entropią schematu  $B$  pod warunkiem zajścia zdarzenia  $A_i$ , co oznaczmy jako  $H(B | A = A_i)$

$$H(AB) = H(A) + \sum_{i=1}^n p_i H(B | A = A_i).$$

Ostatni człon jest w takim razie wartością oczekiwaną wielkości  $H(B)$  w schemacie  $A$ , co oznaczmy jako  $H(B | A)$ . Mamy w takim razie

$$H(AB) = H(A) + H(B | A).$$

Z nierówności Jensena można dodatkowo pokazać, że zachodzi  $H(B | A) \leq H(B)$ .

### 1.14.2 Entropia względna

Dla dwóch ciągłych rozkładów prawdopodobieństwa  $p(\mathbf{x})$ ,  $q(\mathbf{x})$  definiujemy ich entropię względną (nazywaną również *Kullback-Leibler (KL) divergence*) jako

$$\mathbb{D}_{\text{KL}}(p, q) = \int_{\mathbb{R}^n} p(\mathbf{x}) \log \frac{p(\mathbf{x})}{q(\mathbf{x})} d^n \mathbf{x},$$

która określa podobieństwo między dwoma rozkładami prawdopodobieństwa tj. dla ustalonego rozkładu  $p$  dla wszystkich  $q$  zachodzi  $\mathbb{D}_{\text{KL}}(p, q) \geq 0$ , przy czym równość zachodzi iff  $p = q$  (ponownie nierówność Jensena).

Rozważmy teraz rozkład łączny  $p(\mathbf{x}, \mathbf{y})$ . Jeśli zmienne losowe  $\mathbf{x}, \mathbf{y}$  są niezależne to  $p(\mathbf{x}, \mathbf{y}) = p(\mathbf{x})p(\mathbf{y})$ . Jeśli zmienne nie są niezależne to możemy określić stopień ich zależności właśnie poprzez entropię względną między rozkładem łącznym  $p(\mathbf{x}, \mathbf{y})$ , a rozkładem faktoryzowanym  $p(\mathbf{x})p(\mathbf{y})$ . Wielkość taką nazywamy informacją wzajemną (z ang/ *mutual information*)

$$\mathbb{I}(\mathbf{x}, \mathbf{y}) = \mathbb{D}_{\text{KL}}(p(\mathbf{x}, \mathbf{y}), p(\mathbf{x})p(\mathbf{y})) = \int_{\mathbb{R}^n \times \mathbb{R}^m} p(\mathbf{x}, \mathbf{y}) \log \left\{ \frac{p(\mathbf{x}, \mathbf{y})}{p(\mathbf{x})p(\mathbf{y})} \right\} d^n \mathbf{x} d^m \mathbf{y} .$$

## 1.15 Wnioskowanie statystyczne

Modelem statystycznym nazwiemy parę  $(\chi, \mathcal{P})$ , gdzie  $\mathcal{P}$  jest rodziną rozkładów prawdopodobieństwa w zbiorze  $\chi$ , przy czym będziemy zakładać  $\chi = \mathbb{R}^n$

$$\mathcal{P} := \{p(\mathbf{x} \mid \theta) \mid \theta \in \Theta\} ,$$

gdzie  $\Theta$  jest zbiorem parametrów modelu  $\mathcal{P}$ . Prostą próbą losową w modelu  $\mathcal{P}$  nazwiemy ciąg niezależnych zmiennych losowych  $X_1, \dots, X_n$  o wartościach w  $\mathbb{R}^n$  i pochodzących z tego samego rozkładu  $p(\mathbf{x} \mid \theta) \in \mathcal{P}$  (w angielskiej terminologii taki ciąg zmiennych losowych nazwiemy *i.i.d.* tj. *independent and identically distributed*). Statystyką z kolei nazwiemy zmienną losową  $T$  będącą funkcją prostej próby losowej tj.  $T = T(X_1, \dots, X_n)$ . Być może najważniejszym przykładem statystyki jest średnia oznaczana jako  $\bar{X}$

$$\bar{X}(X_1, \dots, X_n) := \frac{X_1 + \dots + X_n}{n} .$$

Wartość oczekiwana statystyki średniej  $\bar{X}(X_1, \dots, X_n)$  dla  $X_i$  z rozkładu  $X \sim \mathcal{D}$  o gęstości  $p$  wynosi

$$\mathbb{E}[\bar{X}] = \int \dots \int \frac{1}{n} \left( \sum_{i=1}^n X_i \right) p(X_1) \dots p(X_n) dX_1 \dots dX_n = \mathbb{E}[X] .$$

Wariancja statystyki średniej wynosi z kolei

$$\begin{aligned}\text{Var}[\bar{X}] &= \mathbb{E}[\bar{X}^2] - \mathbb{E}[\bar{X}]^2 \\ &= \int \cdots \int \frac{1}{n^2} \left( \sum_{i=1}^n X_i^2 + \underbrace{\sum_{i \neq j} X_i X_j}_{n(n-1)} \right) p(X_1) \cdots p(X_n) dX_1 \cdots dX_n - \mathbb{E}[X]^2 \\ &= \frac{1}{n} \mathbb{E}[X^2] + \frac{n(n-1)}{n^2} \mathbb{E}[X]^2 - \mathbb{E}[X]^2 = \frac{1}{n} [\mathbb{E}[X^2] - \mathbb{E}[X]^2] = \frac{1}{n} \text{Var}[X].\end{aligned}$$

## 1.16 Twierdzenie Gliwenki–Cantelliego

Dystrybuantą empiryczną nazywa się funkcję

$$\hat{F}(x) = \frac{1}{N} \# \{i \in \{1, \dots, N\} \mid x_i \leq x\},$$

gdzie  $\{x_1, \dots, x_N\}$  jest realizacją prostej próby losowej. Twierdzenie Gliwenki–Cantelliego stwierdza, iż jeśli  $F(x)$  jest dystrybuantą pewnego rozkładu prawdopodobieństwa to

$$\sup_{x \in \mathbb{R}} |\hat{F}_n(x) - F(x)| \rightarrow 0, \text{ przy } n \rightarrow \infty.$$

## 1.17 Silne prawo wielkich liczb

Niech  $(X_n)$  będzie ciągiem zmiennych losowych i.i.d. z pewnego rozkładu  $X \sim \mathcal{D}$ . Przez  $(\bar{X}_n)$  oznaczmy ciąg średnich częściowych tj.

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i.$$

Wówczas zachodzi silne prawo wielkich liczb

$$P\left(\lim_{n \rightarrow \infty} \bar{X}_n = \mathbb{E}[X]\right) = 1,$$

czyli średnia próbek zbiega do wartości oczekiwanej z prawdopodobieństwem 1.

Silne prawo wielkich liczb daje nam potężne narzędzie do szacowania wartości oczekiwanych, gdyż możemy je przybliżać średnią z dużej liczby próbek losowych, a dokładność tego przybliżenia zależy jedynie od liczby próbek i wariancji  $X$ . Jeśli  $X$  jest zmienną wielowymiarową to dokładność przybliżenia nie zależy wprost od liczby wymiarów i unikamy tzw. *curse of dimensionality*.

## 1.18 Centralne Twierdzenie Graniczne

Niech  $(X_n)$  będzie ciągiem  $k$ -wymiarowych zmiennych losowych i.i.d. z dowolnego rozkładu  $X \sim \mathcal{D}$  o wartości oczekiwanej  $\boldsymbol{\mu} = \mathbb{E}[\mathbf{x}]$  i odwracalnej macierzy kowariancji  $\boldsymbol{\Sigma}$ . Oznaczając przez  $(\bar{X}_n)$  ciąg średnich częściowych ciągu  $(X_n)$  zachodzi

$$\sqrt{n}(\bar{X}_n - \boldsymbol{\mu}) \rightarrow Z \sim \mathcal{N}(\mathbf{0}, \boldsymbol{\Sigma}).$$

Oznacza to, iż dla ciągu  $X_1, \dots, X_n$  zmiennych losowych i.i.d. z praktycznie dowolnego rozkładu  $X \sim \mathcal{D}$  dla odpowiednio dużych  $n$  średnią z próbek możemy traktować jako zmienną losową o rozkładzie normalnym  $\mathcal{N}(\boldsymbol{\mu}, n^{-1/2}\boldsymbol{\Sigma})$ .

## 1.19 Estymatory punktowe MLE i MAP

Rozważamy model statystyczny  $\mathcal{P} = \{p(\mathbf{x} | \theta) | \theta \in \Theta\}$ . Estymatorem parametru  $\theta$  nazwiemy statystykę  $\hat{\theta}(X_1, \dots, X_n)$  służącą do oszacowania wartości tego parametru. Wartość tej statystyki dla konkretnej realizacji prostej próby losowej  $\hat{\theta}(\mathbf{x}_1, \dots, \mathbf{x}_n)$  nazwiemy estymatą parametru  $\theta$ . Dodatkowo definiujemy obciążenie (z ang. *bias*) estymatora jako wielkość

$$\mathbb{B}[\hat{\theta}] := \mathbb{E}[\hat{\theta}] - \theta.$$

Zasadniczo będą nas interesować dwa rodzaje estymat: MLE i MAP. W przypadku estymaty MLE (z ang. *Maximum Likelihood Estimate*) definiujemy funkcję wiarygodności (*likelihood*) dla modelu  $\mathcal{P} = \{p(\mathbf{x} | \theta) | \theta \in \Theta\}$  i realizacji prostej próby losowej (którą nazwiemy również danymi lub obserwacjami)  $D = (\mathbf{x}_1, \dots, \mathbf{x}_n)$  jako

$$p(D | \theta) = \prod_{i=1}^n p(\mathbf{x}_i | \theta).$$

Estymatą MLE nazywamy taką wartość parametru  $\theta_{\text{MLE}} \in \Theta$ , że

$$p(D | \theta_{\text{MLE}}) = \max_{\theta \in \Theta} p(D | \theta).$$

Ponieważ znajdowanie maksimum funkcji będącej iloczynem nie jest zadaniem przyjemnym (choćby obliczanie pochodnych iloczynu funkcji jest trudniejsze od sumy), więc wprowadzamy zanegowaną logarytmiczną funkcję wiarygodności

$$\ell(D | \theta) = -\log p(D | \theta) = -\sum_{i=1}^n \log p(\mathbf{x}_i | \theta),$$

wówczas ze względu na fakt, iż funkcja  $\log x$  jest ściśle rosnąca estymatę MLE możemy równoważnie wyznaczyć jako

$$\ell(D | \theta_{\text{MLE}}) = \min_{\theta \in \Theta} \ell(D | \theta).$$

Funkcję  $\ell$  będziemy również nazywać funkcją kosztu.

W przypadku estymaty MAP (z ang. *Maximum a posteriori estimate*) wprowadzamy gęstość rozkładu a posteriori jako

$$p(\theta \mid D) = \frac{1}{Z} p(D \mid \theta) \pi(\theta),$$

gdzie  $Z$  jest stałą wynikającą z warunku unormowania, a  $\pi(\theta)$  to gęstość prawdopodobieństwa opisująca rozkład a priori parametru  $\theta$ . Estymatą MAP nazywamy taką wartość parametru  $\theta_{\text{MAP}} \in \Theta$ , że

$$p(\theta_{\text{MAP}} \mid D) = \max_{\theta \in \Theta} p(\theta \mid D).$$

Zauważmy przy tym iż liczba  $Z$  nie jest nam potrzebna, gdyż wystarczy zmaksymalizować licznik tj.

$$\theta_{\text{MAP}} = \arg \max_{\theta \in \Theta} p(D \mid \theta) \pi(\theta).$$

---



## 2 Probabilistyczne uczenie maszynowe

### 2.1 Wnioskowanie Bayesowskie

Zajmiemy się teraz wnioskowaniem opartym na twierdzeniu Bayesa. Rozpatrujemy model statystyczny  $\mathcal{P} = \{p(\mathbf{x} | \theta) | \theta \in \Theta\}$ . Załóżmy, iż mamy obserwacje  $D = (\mathbf{x}_1, \dots, \mathbf{x}_n)$ , wówczas twierdzenie Bayesa możemy zapisać jako

$$p(\theta | D) = \frac{p(D | \theta)\pi(\theta)}{p_D(D)} = \frac{p(D | \theta)\pi(\theta)}{\int_{\Theta} p(D | \theta)\pi(\theta) d\theta},$$

gdzie  $p(\theta | D)$  nazywamy rozkładem a posteriori (posteriorem),  $p(D | \theta)$  – wiarygodnością (likelihood), a  $\pi(\theta)$  – rozkładem a priori (priorem).

Całe wnioskowanie Bayesowskie opiera się na wyznaczeniu rozkładu a posteriori, który wyraża całą naszą wiedzę o estymowanym parametrze  $\theta$ . Na podstawie tego rozkładu możemy wyznaczyć estymatę punktową MAP maksymalizującą gęstość prawdopodobieństwa a posteriori, jak również niepewność związaną z wyznaczeniem tej estymaty np. poprzez wyznaczenie przedziału wiarygodności  $C_{1-\alpha}(\theta | D) = [\theta_l; \theta_u]$  takiego, że

$$P(\theta \in [\theta_l; \theta_u] | D) = 1 - \alpha,$$

dla ustalonego  $0 < \alpha < 1$ . Możemy również skonstruować rozkład predykcyjny (z ang. *posterior predictive distribution*) określający prawdopodobieństwo zaobserwowania nowej obserwacji  $\mathbf{x}$

$$p(\mathbf{x} | D) = \int_{\Theta} p(\mathbf{x} | \theta)p(\theta | D) d\theta.$$

Znając rozkład a posteriori estymowanego parametru  $\theta$  możemy nie tylko wyznaczyć estymaty punktowe, wartości oczekiwane i przedziały wiarygodności, ale również znaleźć estymator Bayesa (z ang. *Bayes estimator*), który minimalizuje wartość oczekiwaną pewnej funkcji kosztu (z ang. *loss/cost function*)  $L(\theta, \hat{\theta})$  po wszystkich estymatorach  $\hat{\theta}$

$$\theta_{\text{Bayes}} = \arg \min_{\hat{\theta}} \int_{\Theta} L(\theta, \hat{\theta})p(\theta | D) d\theta.$$

Całkę w powyższym wzorze nazywa się również funkcją ryzyka (z ang. *risk function*)  $R(\hat{\theta})$ , która określa oczekiwaną stratę spowodowaną wykorzystaniem danego estymatora parametru  $\theta$ . W przypadku gdy funkcja kosztu ma postać błędu kwadratowego (L2)

$$L(\theta, \hat{\theta}) = (\theta - \hat{\theta})^2$$

funkcję ryzyka możemy zapisać jako

$$\begin{aligned} R(\hat{\theta}) &= \int_{\Theta} \theta^2 p(\theta | D) d\theta - 2\hat{\theta} \int_{\Theta} \theta p(\theta | D) d\theta + \hat{\theta}^2 \\ &= \text{Var}[\theta | D] + \mathbb{E}[\theta | D]^2 - 2\hat{\theta} \mathbb{E}[\theta | D] + \hat{\theta}^2 \\ &= \text{Var}[\theta | D] + \left( \mathbb{E}[\theta | D] - \hat{\theta} \right)^2. \end{aligned}$$

## 2.2 Bayesowski wybór modeli

Założmy, iż mamy rodzinę  $\mathcal{M}$  modeli statystycznych (może to być zbiór dyskretny lub zbiór modeli indeksowanych ciągłym, wielowymiarowym parametrem  $\boldsymbol{\lambda}$ ). Naszym zadaniem jest wybór najbardziej prawdopodobnego modelu dla danych  $D$ . Możemy na to zadanie patrzeć jako zadanie z teorii decyzji: dla danej funkcji kosztu  $L(M, M^*)$  i rozkładu a posteriori nad modelami  $p(M | D)$  chcemy wybrać model, który minimalizuje ryzyko  $\mathbb{E}[L(M, M^*)]$ . Jeśli jako koszt wybierzemy tzw.  $0-1$  loss tj.

$$L(M, M^*) = \begin{cases} 0 & , \text{jeśli } M = M^* \\ 1 & , \text{w.p.p.} \end{cases}$$

to

$$\mathbb{E}[L(M, M^*)] = 1 - p(M^* | D)$$

i wybieramy model  $M$  o największym prawdopodobieństwie (estymata MAP). Pozostaje tylko wyznaczenie  $p(M | D)$

$$p(M | D) = \frac{p(D | M)\pi(M)}{\sum_{M \in \mathcal{M}} p(D | M)\pi(M)}.$$

Jeśli jako prior przyjmiemy rozkład jednostajny  $\pi(M) = |\mathcal{M}|^{-1}$  to estymata MAP sprowadza się do MLE czyli szukamy modelu

$$M^* = \arg \max_{M \in \mathcal{M}} p(D | M).$$

Jeśli przez  $\theta_M$  oznaczymy parametry modelu  $M$  to

$$p(D | M) = \int_{\Theta_M} p(D | \theta_M) \pi(\theta_M) d\theta_M.$$

Powyższą wielkość nazywamy wiarygodnością brzegową (z ang. *marginal likelihood*) lub *model evidence*.

## 2.3 Estymator jądrowy gęstości (KDE)

Założmy, że mamy zbiór obserwacji iid  $\{\mathbf{x}_1, \dots, \mathbf{x}_m\}$  taki, że  $\mathbf{x}_i \sim \mathcal{D}$  dla pewnego  $n$ -wymiarowego ciągłego rozkładu prawdopodobieństwa  $\mathcal{D}$  z nieznaną gęstością prawdopodobieństwa  $p(\mathbf{x})$ . Chcemy znaleźć estymator  $\hat{p}(\mathbf{x})$  tej funkcji. Estymatorem jądrowym gęstości funkcji  $p$  (z ang. *kernel density estimator*) nazywamy funkcję

$$\hat{p}(\mathbf{x}) := \frac{1}{mh^n} \sum_{i=1}^m K\left(\frac{\mathbf{x} - \mathbf{x}_i}{h}\right),$$

gdzie  $h \in \mathbb{R}$  jest pewnym hiperparametrem zwanym *bandwidth*, a  $K : \mathbb{R}^n \mapsto [0; \infty)$  to tzw. funkcja jądrowa będąca parzystą funkcją posiadającą w 0 maksimum globalne oraz spełniającą warunek unormowania

$$\int_{\mathbb{R}^n} K(\mathbf{x}) d^n \mathbf{x} = 1.$$

Ze statystycznego punktu widzenia, postać jądra nie ma istotnego znaczenia i wybór funkcji  $K$  może być arbitralny, uwzględniający przede wszystkim pożądaną własność otrzymanego estymatora, na przykład klasę jego regularności (ciągłość, różniczkowalność itp.). W przypadku jednowymiarowym jako funkcję  $K$  przyjmuje się klasyczne postacie gęstości rozkładów probabilistycznych, na przykład gęstość rozkładu normalnego. W przypadku wielowymiarowym stosuje się tzw. jądro radialne tj. dla jądra jednowymiarowego  $K$  wielowymiarowe jądro radialne definiujemy jako

$$K(\mathbf{x}) = K(\|\mathbf{x}\|)$$

dla pewnej normy (typowo normy euklidesowej)  $\|\cdot\|$ .

## 2.4 Modele Gaussowskie

Jak już wspomnieliśmy w przypadku gdy zmienna losowa ma wielowymiarowy rozkład normalny  $\mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$  wszystkie rozkłady brzegowe i warunkowe są również rozkładami normalnymi. W szczególnym przypadku gdy zmienne  $k$  i  $n-k$ -wymiarowe  $\mathbf{x}$  i  $\mathbf{y}$  mają łącznie rozkład normalny

$$\begin{bmatrix} \mathbf{x} \\ \mathbf{y} \end{bmatrix} \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma}),$$

gdzie

$$\boldsymbol{\mu} = \begin{bmatrix} \boldsymbol{\mu}_x \\ \boldsymbol{\mu}_y \end{bmatrix}, \quad \boldsymbol{\Sigma} = \begin{bmatrix} \boldsymbol{\Sigma}_{xx} & \boldsymbol{\Sigma}_{xy} \\ \boldsymbol{\Sigma}_{yx} & \boldsymbol{\Sigma}_{yy} \end{bmatrix}$$

można pokazać iż

$$\mathbf{x} \mid \mathbf{y} \sim \mathcal{N}(\boldsymbol{\mu}_{\mathbf{x}|\mathbf{y}}, \boldsymbol{\Sigma}_{\mathbf{x}|\mathbf{y}}), \quad \mathbf{y} \sim \mathcal{N}(\boldsymbol{\mu}_{\mathbf{y}}, \boldsymbol{\Sigma}_{\mathbf{y}\mathbf{y}}),$$

gdzie

$$\begin{aligned} \boldsymbol{\mu}_{\mathbf{x}|\mathbf{y}} &= \boldsymbol{\mu}_{\mathbf{x}} + \boldsymbol{\Sigma}_{\mathbf{xy}} \boldsymbol{\Sigma}_{\mathbf{yy}}^{-1} (\mathbf{y} - \boldsymbol{\mu}_{\mathbf{y}}) \\ \boldsymbol{\Sigma}_{\mathbf{x}|\mathbf{y}} &= \boldsymbol{\Sigma}_{\mathbf{xx}} - \boldsymbol{\Sigma}_{\mathbf{xy}} \boldsymbol{\Sigma}_{\mathbf{yy}}^{-1} \boldsymbol{\Sigma}_{\mathbf{yx}} \end{aligned}.$$

## 2.5 Liniowe modele Gaussowskie

Powyższe własności rozkładów łącznych pozwalają jawnie wnioskować w tzw. liniowych modelach Gaussowskich (z ang. *Linear Gaussian Models*). Załóżmy, iż nasze obserwacje są modelowane przez  $n$ -wymiarową zmienną losową  $\mathbf{y}$  o rozkładzie normalnym z estymowanym parametrem  $\mathbf{x}$  i znanymi parametrami  $\mathbf{A}, \mathbf{b}, \boldsymbol{\Sigma}_{\mathbf{y}}$  tak, że wiarygodność ma postać

$$\mathbf{y} \mid \mathbf{x} \sim \mathcal{N}(\mathbf{Ax} + \mathbf{b}, \boldsymbol{\Sigma}_{\mathbf{y}}),$$

gdzie  $\mathbf{A}$  jest macierzą wymiaru  $n \times k$ . Jako prior na parametr  $\mathbf{x}$  przyjmujemy również rozkład normalny o pewnych zadanych parametrach  $\boldsymbol{\mu}_{\mathbf{x}}, \boldsymbol{\Sigma}_{\mathbf{x}}$  (taki wybór rozkładu a priori nazywamy rozkładem sprzężonym do wiarygodności)

$$\mathbf{x} \sim \mathcal{N}(\boldsymbol{\mu}_{\mathbf{x}}, \boldsymbol{\Sigma}_{\mathbf{x}}).$$

Wówczas łatwo pokazać, iż rozkład a posteriori jest rozkładem normalnym

$$\mathbf{x} \mid \mathbf{y} \sim \mathcal{N}(\boldsymbol{\mu}_{\mathbf{x}|\mathbf{y}}, \boldsymbol{\Sigma}_{\mathbf{x}|\mathbf{y}})$$

z parametrami

$$\begin{aligned} \boldsymbol{\Sigma}_{\mathbf{x}|\mathbf{y}} &= [\boldsymbol{\Sigma}_{\mathbf{x}}^{-1} + \mathbf{A}^{\top} \boldsymbol{\Sigma}_{\mathbf{y}}^{-1} \mathbf{A}]^{-1} \\ \boldsymbol{\mu}_{\mathbf{x}|\mathbf{y}} &= \boldsymbol{\Sigma}_{\mathbf{x}|\mathbf{y}} [\mathbf{A}^{\top} \boldsymbol{\Sigma}_{\mathbf{y}}^{-1} (\mathbf{y} - \mathbf{b}) + \boldsymbol{\Sigma}_{\mathbf{x}}^{-1} \boldsymbol{\mu}_{\mathbf{x}}] \end{aligned}.$$

Założmy teraz, iż mamy ciąg obserwacji  $(\mathbf{y}_1, \dots, \mathbf{y}_m)$ . Wnioskowanie Bayesowskie możemy wówczas stosować iteracyjnie tzn. na początku dla 0 obserwacji rozkład estymowanego parametru jest opisany przez prior  $\mathcal{N}(\boldsymbol{\mu}_0, \boldsymbol{\Sigma}_0)$ . Po zaobserwowaniu jednego  $\mathbf{y}_1$  aktualizujemy nasze przekonania co do parametru  $\mathbf{x}$  zgodnie z powyższym wzorem i otrzymujemy rozkład normalny o parametrach

$$\begin{aligned} \boldsymbol{\Sigma}_1 &= [\boldsymbol{\Sigma}_0^{-1} + \mathbf{A}^{\top} \boldsymbol{\Sigma}_{\mathbf{y}}^{-1} \mathbf{A}]^{-1} \\ \boldsymbol{\mu}_1 &= \boldsymbol{\Sigma}_1 [\mathbf{A}^{\top} \boldsymbol{\Sigma}_{\mathbf{y}}^{-1} (\mathbf{y}_1 - \mathbf{b}) + \boldsymbol{\Sigma}_0^{-1} \boldsymbol{\mu}_0] \end{aligned}.$$

Po zaobserwowaniu kolejnego  $\mathbf{y}_2$  ponownie wykorzystujemy powyższe wzory ale jako prior wykorzystując rozkład w poprzedniej iteracji. W ogólności możemy zapisać wzór rekurencyjny na  $m + 1$  rozkład jako

$$\begin{aligned}\boldsymbol{\Sigma}_{m+1} &= [\boldsymbol{\Sigma}_m^{-1} + \mathbf{A}^\top \boldsymbol{\Sigma}_y^{-1} \mathbf{A}]^{-1} \\ \boldsymbol{\mu}_{m+1} &= \boldsymbol{\Sigma}_{m+1} [\mathbf{A}^\top \boldsymbol{\Sigma}_y^{-1} (\mathbf{y}_{m+1} - \mathbf{b}) + \boldsymbol{\Sigma}_m^{-1} \boldsymbol{\mu}_m] \quad ,\end{aligned}$$

skąd możemy od razu podać wzór na parametry  $m$ -tego rozkładu

$$\begin{aligned}\boldsymbol{\Sigma}_m &= [\boldsymbol{\Sigma}_0^{-1} + m \mathbf{A}^\top \boldsymbol{\Sigma}_y^{-1} \mathbf{A}]^{-1} \\ \boldsymbol{\mu}_m &= \boldsymbol{\Sigma}_m \left[ \mathbf{A}^\top \boldsymbol{\Sigma}_y^{-1} \left( \sum_{i=1}^m \mathbf{y}_i - m \mathbf{b} \right) + \boldsymbol{\Sigma}_0^{-1} \boldsymbol{\mu}_0 \right] \quad .\end{aligned}$$

Taki sam wynik można by uzyskać rozpatrując łączny rozkład a posteriori dla obserwacji  $D = (\mathbf{y}_1, \dots, \mathbf{y}_m)$  tj.

$$\begin{aligned}p(\mathbf{x} \mid D) &\cong \pi(\mathbf{x}) \prod_{i=1}^m p(\mathbf{y}_i \mid \mathbf{x}) \cong \\ &\exp \left\{ -\frac{1}{2} \left[ (\mathbf{x} - \boldsymbol{\mu}_0)^\top \boldsymbol{\Sigma}_0^{-1} (\mathbf{x} - \boldsymbol{\mu}_0) + \sum_{i=1}^m (\mathbf{y}_i - \mathbf{A}\mathbf{x} - \mathbf{b})^\top \boldsymbol{\Sigma}_y^{-1} (\mathbf{y}_i - \mathbf{A}\mathbf{x} - \mathbf{b}) \right] \right\} .\end{aligned}$$

## 2.6 Regresja liniowa

Założmy, iż modelujemy obserwacje postaci  $(y, \mathbf{x})$  gdzie  $y$  to skalar zwany zmienną objaśnianą, którego wartość obserwujemy, a  $\mathbf{x}$  to wektor zmiennych objaśniających, który kontrolujemy tj. zakładamy, iż wektor  $\mathbf{x}$  dla danego pomiaru  $y$  znamy dokładnie. Dodatkowo zakładamy, iż  $y$  zależy liniowo od  $\mathbf{x}$  tj.

$$y = \mathbf{w}^\top \mathbf{x} + \epsilon ,$$

gdzie  $\epsilon \sim \mathcal{N}(0, \sigma^2)$  dla znanego  $\sigma$  jest tzw. błędem losowym, a  $\mathbf{w}$  jest estymowanym przez nas parametrem. Możemy zatem zapisać

$$y \mid \mathbf{w} \sim \mathcal{N}(\mathbf{w}^\top \mathbf{x}, \sigma^2) .$$

Powiedzmy, iż zaobserwowaliśmy ciąg obserwacji  $D = (y_1, \dots, y_m)$  dla zadanych (lub dokładnie znanych) przez nas  $(\mathbf{x}_1, \dots, \mathbf{x}_m)$ . Wiarygodność ma zatem postać

$$p(D \mid \mathbf{w}) \cong \prod_{i=1}^m \exp \left\{ -\frac{1}{2\sigma^2} (y_i - \mathbf{w}^\top \mathbf{x}_i)^2 \right\} .$$

W przypadku regresji liniowej zamiast pełnego wnioskowania Bayesowskiego o parametrze  $\mathbf{w}$  często stosuje się prostsze podejście polegające na znalezieniu estymaty punktowej MLE. Zanegowana logarytmiczna funkcja wiarygodności ma postać

$$\ell(D | \mathbf{w}) = \frac{1}{2\sigma^2} \sum_{i=1}^m (y_i - \mathbf{w}^\top \mathbf{x}_i)^2 + \text{const.}$$

Człon stały możemy oczywiście pominąć i zapisać

$$\ell(D | \mathbf{w}) \cong \sum_{i=1}^m (y_i - \mathbf{w}^\top \mathbf{x}_i)^2 = (\mathbf{y} - \mathbf{X}\mathbf{w})^\top (\mathbf{y} - \mathbf{X}\mathbf{w}) ,$$

gdzie

$$\mathbf{y} = \begin{bmatrix} y_1 \\ \vdots \\ y_m \end{bmatrix} , \quad \mathbf{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \vdots \\ \mathbf{x}_m^\top \end{bmatrix} .$$

Ponieważ otrzymana funkcja  $\ell$  ma postać formy kwadratowej, więc problem optymalizacyjny polegający na znalezieniu minimum  $\ell$  nazywa się metodą najmniejszych kwadratów (z ang. *OLS – Ordinary Least Squares*). Aby wyznaczyć estymatę  $\mathbf{w}_{\text{MLE}}$  musimy rozwiązać równanie

$$\frac{\partial \ell}{\partial \mathbf{w}} = \frac{\partial}{\partial \mathbf{w}} [\mathbf{y}^\top \mathbf{y} + \mathbf{w}^\top \mathbf{X}^\top \mathbf{X} \mathbf{w} - 2\mathbf{y}^\top \mathbf{X} \mathbf{w}] = \mathbf{0} ,$$

skąd

$$2\mathbf{X}^\top \mathbf{X} \mathbf{w} - 2\mathbf{X}^\top \mathbf{y} = \mathbf{0} ,$$

zatem

$$\mathbf{w}_{\text{MLE}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y} .$$

Pełniejszą informację o parametrze  $\mathbf{w}$  możemy uzyskać rozpatrując rozkład a posteriori  $p(\mathbf{w} | D)$ . Jeśli jako prior przyjmiemy rozkład normalny z pewnymi parametrami  $\boldsymbol{\mu}_0, \boldsymbol{\Sigma}_0$  to zauważmy, iż otrzymujemy instancję liniowego modelu Gaussowskiego

$$\begin{aligned} \mathbf{y} | \mathbf{w} &\sim \mathcal{N}(\mathbf{X}\mathbf{w}, \sigma^2 \mathbf{1}) \\ \mathbf{w} &\sim \mathcal{N}(\boldsymbol{\mu}_0, \boldsymbol{\Sigma}_0) \end{aligned} ,$$

skąd rozkład a posteriori jest rozkładem normalnym

$$\mathbf{w} | \mathbf{y} \sim \mathcal{N}(\boldsymbol{\mu}_m, \boldsymbol{\Sigma}_m)$$

o parametrach

$$\begin{aligned}\boldsymbol{\Sigma}_m &= [\boldsymbol{\Sigma}_0^{-1} + \sigma^{-2} \mathbf{X}^\top \mathbf{X}]^{-1} \\ \boldsymbol{\mu}_m &= \boldsymbol{\Sigma}_m [\sigma^{-2} \mathbf{X}^\top \mathbf{y} + \boldsymbol{\Sigma}_0^{-1} \boldsymbol{\mu}_0]\end{aligned}.$$

W powyższych wzorach nazwy parametrów nie są przykładowe: po zaobserwowaniu 0 przykładów rozkład parametru  $\mathbf{w}$  jest rozkładem a priori  $\mathcal{N}(\boldsymbol{\mu}_0, \boldsymbol{\Sigma}_0)$ ; po zaobserwowaniu po jednej wartości  $y_i$  w  $m$  zadanych (znanych dokładnie) punktach  $\mathbf{x}_i$  otrzymujemy rozkład a posteriori  $\mathcal{N}(\boldsymbol{\mu}_m, \boldsymbol{\Sigma}_m)$ . Gdybyśmy w każdym z  $m$  punktów  $\mathbf{x}_i$  dokonywali pomiaru  $y_i$   $s$ -krotnie to wtedy wykorzystując wzory wyprowadzone przy iteracyjnym stosowaniu wnioskowania w liniowym modelu Gaussowskim otrzymujemy rozkład normalny o parametrach

$$\begin{aligned}\boldsymbol{\Sigma}_{m;s} &= \left[ \boldsymbol{\Sigma}_0^{-1} + \frac{s}{\sigma^2} \mathbf{X}^\top \mathbf{X} \right]^{-1} \\ \boldsymbol{\mu}_{m;s} &= \boldsymbol{\Sigma}_{m;s} \left[ \sigma^{-2} \mathbf{X}^\top \sum_{i=1}^s \mathbf{y}_i + \boldsymbol{\Sigma}_0^{-1} \boldsymbol{\mu}_0 \right]\end{aligned}.$$

Rozkład predykcyjny dla nowej obserwacji  $y$  poczynionej w punkcie  $\mathbf{x}$  jest dany przez

$$p(y | \mathbf{y}) = \int_{\mathbb{R}^n} p(y | \mathbf{w}) p(\mathbf{w} | \mathbf{y}) d^n \mathbf{w}.$$

Nietrudno zauważyć, iż będzie to rozkład normalny o parametrach

$$\begin{aligned}\mu_{y|\mathbf{y}} &= \mathbb{E}[y | \mathbf{y}] = \int_{\mathbb{R}} y p(y | \mathbf{y}) dy = \int_{\mathbb{R}^n} d^n \mathbf{w} p(\mathbf{w} | \mathbf{y}) \int_{\mathbb{R}} dy y p(y | \mathbf{w}) \\ &= \int_{\mathbb{R}^n} d^n \mathbf{w} p(\mathbf{w} | \mathbf{y}) \mathbf{x}^\top \mathbf{w} = \mathbf{x}^\top \boldsymbol{\mu}_m.\end{aligned}$$

oraz

$$\begin{aligned}\sigma_{y|\mathbf{y}}^2 &= \mathbb{E}[(y - \mu_{y|\mathbf{y}})^2 | \mathbf{y}] = \int_{\mathbb{R}^n} d^n \mathbf{w} p(\mathbf{w} | \mathbf{y}) \int_{\mathbb{R}} dy (y - \mu_{y|\mathbf{y}})^2 p(y | \mathbf{w}) \\ &= \int_{\mathbb{R}^n} d^n \mathbf{w} p(\mathbf{w} | \mathbf{y}) \int_{\mathbb{R}} dy (y^2 + \mu_{y|\mathbf{y}}^2 - 2\mu_{y|\mathbf{y}} y) p(y | \mathbf{w}) \\ &= \int_{\mathbb{R}^n} d^n \mathbf{w} p(\mathbf{w} | \mathbf{y}) (\sigma^2 + (\mathbf{x}^\top \mathbf{w})^2 + \mu_{y|\mathbf{y}}^2 - 2\mu_{y|\mathbf{y}} \mathbf{x}^\top \mathbf{w}) \\ &= \sigma^2 + \int_{\mathbb{R}^n} d^n \mathbf{w} p(\mathbf{w} | \mathbf{y}) (\mathbf{x}^\top \mathbf{w} - \mathbf{x}^\top \boldsymbol{\mu}_m)^2 \\ &= \sigma^2 + \mathbf{x}^\top \mathbb{E}[(\mathbf{w} - \boldsymbol{\mu}_m)(\mathbf{w} - \boldsymbol{\mu}_m)^\top | \mathbf{y}] \mathbf{x} = \sigma^2 + \mathbf{x}^\top \boldsymbol{\Sigma}_m \mathbf{x}.\end{aligned}$$

Powyżej skorzystaliśmy ze znanego faktu, iż dla jednowymiarowej zmiennej losowej zachodzi  $\sigma^2 = \mathbb{E}[(X - \mu_X)^2] = \mathbb{E}[X^2] - \mu_X^2$ , skąd  $\mathbb{E}[X^2] = \sigma^2 + \mu_X^2$ . Podsumowując rozkład predykcyjny ma postać

$$y \mid \mathbf{y} \sim \mathcal{N}(\mathbf{x}^\top \boldsymbol{\mu}_m, \sigma^2 + \mathbf{x}^\top \boldsymbol{\Sigma}_m \mathbf{x}).$$

## 2.7 Regularyzacja

Regularyzacją nazywamy proces polegający na wprowadzeniu ad hoc do zagadnienia optymalizacji dodatkowych członów tak, aby rozwiązanie było regularne (prostsze, nieosobliwe, jednoznaczne ...). W przypadku funkcji kosztu  $\ell$  najczęściej dodajemy człon penalizujący rozwiązania o dużej normie estymowanego parametru postaci

$$\gamma \|\theta\|$$

dla pewnej normy  $\|\cdot\|$  i hiper-parametru  $\gamma$  określającego siłę regularyzacji. W kontekście Bayesowskim regularyzację można również rozumieć jako pewną niechęć ("tłumienie", zachowawczość) modelu do zmiany rozkładu a priori estymowanego parametru po pojawieniu się kolejnych obserwacji.

Przykładowo jeśli w zagadnieniu Bayesowskiej regresji liniowej jako prior przyjmujemy rozkład normalny

$$\mathbf{w} \sim \mathcal{N}(\mathbf{0}, \tau^2 \mathbf{1})$$

to rozkład a posteriori jest rozkładem normalnym o parametrach

$$\begin{aligned} \boldsymbol{\Sigma}_m &= \sigma^2 [\gamma \mathbf{1} + \mathbf{X}^\top \mathbf{X}]^{-1} \\ \boldsymbol{\mu}_m &= [\gamma \mathbf{1} + \mathbf{X}^\top \mathbf{X}]^{-1} \mathbf{X}^\top \mathbf{y} \end{aligned}$$

gdzie  $\gamma = \sigma^2/\tau^2$  jest hiper-parametrem określającym siłę regularyzacji. Zauważmy, że im większa jest wartość  $\gamma$  (mniejsza niepewność związana z rozkładem a priori) tym drugi człon w nawiasie staje się mniej istotny. Taki sam wynik możemy uzyskać metodą OLS jeśli do funkcji kosztu dodamy człon regularyzujący dla zwykłej normy euklidesowej. Zagadnienie minimalizacji funkcji kosztu będącej formą kwadratową z dodanym członem regularyzującym nazywamy również regresją grzbietową.

## 2.8 Procesy Gaussowskie

Jak już wspomnieliśmy macierz kowariancji  $n$ -wymiarowej zmiennej losowej  $\mathbf{x}$  o wartości oczekiwanej  $\boldsymbol{\mu}$  jest zdefiniowana jako

$$\boldsymbol{\Sigma} = \mathbb{E}[(\mathbf{x} - \boldsymbol{\mu})(\mathbf{x} - \boldsymbol{\mu})^\top].$$



Pokazaliśmy również, iż macierz ta jest nieujemnie określona. Dodatkowo pokazujemy, iż dla każdej nieujemnie określonej macierzy symetrycznej  $\mathbf{K}$  wymiaru  $n \times n$  istnieje  $n$ -wymiarowa zmienna losowa o wielowymiarowym rozkładzie normalnym dla której  $\mathbf{K}$  jest macierzą kowariancji. Istotnie dla każdej nieujemnie określonej macierzy symetrycznej istnieje macierz  $\mathbf{L}$  taka, że

$$\mathbf{K} = \mathbf{L}\mathbf{L}^\top,$$

jest to tzw. dekompozycja Choleskiego. Niech  $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{1})$ , wówczas zmienna losowa  $\mathbf{Lz}$  ma rozkład o zerowej wartości oczekiwanej i macierzy kowariancji

$$\mathbb{E}[(\mathbf{Lz})(\mathbf{Lz})^\top] = \mathbb{E}[\mathbf{Lzz}^\top \mathbf{L}^\top] = \mathbf{L}\mathbb{E}[\mathbf{zz}^\top]\mathbf{L}^\top = \mathbf{L}\mathbf{1}\mathbf{L}^\top = \mathbf{K}.$$

Powyższe własności wskazują, iż macierze kowariancji można w pewnym sensie utożsamiać z nieujemnie określonymi macierzami symetrycznymi.

Zdefiniujemy teraz funkcję kowariancji  $k : \mathbb{R}^n \times \mathbb{R}^n \mapsto \mathbb{R}$  taką, że  $\forall m \in \mathbb{N} : \forall X = \{\mathbf{x}_1, \dots, \mathbf{x}_m\} \subset \mathbb{R}^n$  macierz

$$k(X, X) = \begin{bmatrix} k(\mathbf{x}_1, \mathbf{x}_1) & k(\mathbf{x}_1, \mathbf{x}_2) & \cdots & k(\mathbf{x}_1, \mathbf{x}_m) \\ k(\mathbf{x}_2, \mathbf{x}_1) & k(\mathbf{x}_2, \mathbf{x}_2) & \cdots & k(\mathbf{x}_2, \mathbf{x}_m) \\ \vdots & \vdots & \ddots & \vdots \\ k(\mathbf{x}_m, \mathbf{x}_1) & k(\mathbf{x}_m, \mathbf{x}_2) & \cdots & k(\mathbf{x}_m, \mathbf{x}_m) \end{bmatrix}$$

jest dodatnio określoną macierzą symetryczną. Funkcję  $k$  nazywamy również jądrem dodatnio określonym (z ang. *positive definite kernel*) lub jądrem Mercera. Dla dwóch zbiorów punktów  $X = \{\mathbf{x}_1, \dots, \mathbf{x}_m\} \subset \mathbb{R}^n$  i  $Y = \{\mathbf{y}_1, \dots, \mathbf{y}_s\} \subset \mathbb{R}^n$  i funkcji kowariancji  $k$  wprowadzimy oznaczenie

$$k(X, Y) := \begin{bmatrix} k(\mathbf{x}_1, \mathbf{y}_1) & k(\mathbf{x}_1, \mathbf{y}_2) & \cdots & k(\mathbf{x}_1, \mathbf{y}_s) \\ k(\mathbf{x}_2, \mathbf{y}_1) & k(\mathbf{x}_2, \mathbf{y}_2) & \cdots & k(\mathbf{x}_2, \mathbf{y}_s) \\ \vdots & \vdots & \ddots & \vdots \\ k(\mathbf{x}_m, \mathbf{y}_1) & k(\mathbf{x}_m, \mathbf{y}_2) & \cdots & k(\mathbf{x}_m, \mathbf{y}_s) \end{bmatrix}.$$

Poniżej podajemy kilka przykładów funkcji kowariancji

- *Gaussian kernel* dla normy  $\|\cdot\|$  i hiper-parametrów  $a, l$  (amplituda i skala długości)

$$k(\mathbf{x}, \mathbf{y}) = a^2 \exp \left\{ -\frac{1}{2l^2} \|\mathbf{x} - \mathbf{y}\|^2 \right\}$$

- *Periodic kernel* dla normy  $\|\cdot\|$  i hiper-parametrów  $a, l, p$  (amplituda, skala długości, okres zmienności)

$$k(\mathbf{x}, \mathbf{y}) = a^2 \exp \left\{ -\frac{2}{l^2} \sin^2 \left( \frac{\pi}{p} \|\mathbf{x} - \mathbf{y}\| \right) \right\}$$

- *White noise kernel* dla hiper-parametru  $\sigma$

$$k(\mathbf{x}, \mathbf{y}) = \sigma^2 \delta_{\mathbf{x}, \mathbf{y}}$$

- *Matérn kernel* dla normy  $\|\cdot\|$  i hiper-parametrów  $a, l, \nu$  (amplituda, skala długości, regularność)

$$k(\mathbf{x}, \mathbf{y}) = a^2 \frac{2^{1-\nu}}{\Gamma(\nu)} \left( \frac{\sqrt{2\nu}}{l} \|\mathbf{x} - \mathbf{y}\| \right)^\nu K_\nu \left( \frac{\sqrt{2\nu}}{l} \|\mathbf{x} - \mathbf{y}\| \right),$$

gdzie  $\Gamma(x)$  to funkcja gamma Eulera, a  $K_\nu(x)$  to zmodyfikowana funkcja Bessela 2-go rodzaju rzędu  $\nu$ .

Dodatkowo suma lub iloczyn dwóch funkcji kowariancji oraz złożenie funkcji kowariancji z wielomianem o nieujemnych współczynnikach jest również funkcją kowariancji.

Procesem Gaussowskim (z ang. *Gaussian Process*) nazywamy rodzinę skalar-nych zmiennych losowych indeksowanych przez punkty  $\mathbf{x} \in \mathbb{R}^n$

$$\mathcal{GP} = \{f_{\mathbf{x}} \mid \mathbf{x} \in \mathbb{R}^n\}$$

taką że każdy skończony podzbiór  $\mathcal{GP}$  ma łącznie wielowymiarowy rozkład normalny tj. dla dowolnego zbioru  $X = \{\mathbf{x}_1, \dots, \mathbf{x}_m\} \subset \mathbb{R}^n$  zachodzi

$$\begin{bmatrix} f_{\mathbf{x}_1} \\ \vdots \\ f_{\mathbf{x}_m} \end{bmatrix} \sim \mathcal{N}(\boldsymbol{\mu}_X, \boldsymbol{\Sigma}_X).$$

Zauważmy, iż process Gaussowski możemy jednoznacznie zdefiniować podając przepisy na parametry  $\boldsymbol{\mu}_X$  i  $\boldsymbol{\Sigma}_X$  dla dowolnego zbioru  $X$ . W praktyce często przyjmujemy  $\boldsymbol{\mu}_X = \mathbf{0}$ , natomiast przepisem na macierz kowariancji może być zdefiniowana wyżej funkcja kowariancji  $k(X, X)$  tj.

$$\begin{bmatrix} f_{\mathbf{x}_1} \\ \vdots \\ f_{\mathbf{x}_m} \end{bmatrix} \sim \mathcal{N}(\mathbf{0}, k(X, X)).$$

Process Gaussowski daje nam w praktyce rozkład prawdopodobieństwa nad funkcjami  $f : \mathbb{R}^n \mapsto \mathbb{R}$ , których charakter jest określony przez jądro  $k$  (np. funkcja gładka dla jądra Gaussowskiego, okresowa dla jądra periodycznego, itp.). Zauważmy, że nie wnioskujemy tu o parametrach konkretnej rodziny funkcji (jak w przypadku regresji liniowej); interesuje nas jedynie rozkład predykcyjny. Załóżmy,

iż w zadanych (lub dokładnie znanych) przez nas punktach  $X = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_m\}$  zaobserwowaliśmy wartości pewnej funkcji, o których zakładamy, iż pochodzą z procesu Gaussowskiego zadanego jądrem  $k$ , które wyraża nasze założenia a priori co do charakteru badanej funkcji

$$\mathbf{f}_X = \begin{bmatrix} f_{\mathbf{x}_1} \\ \vdots \\ f_{\mathbf{x}_m} \end{bmatrix} \sim \mathcal{N}(\mathbf{0}, k(X, X)).$$

Powiedzmy, iż chcemy znać wartości  $\mathbf{f}_Y$  tej funkcji w zadanych punktach  $Y = \{\mathbf{y}_1, \mathbf{y}_2, \dots, \mathbf{y}_s\}$ . Ponieważ założyliśmy, iż wartości funkcji pochodzą z procesu Gaussowskiego, więc rozkład łączny  $\mathbf{f}_X$  i  $\mathbf{f}_Y$  jest rozkładem normalnym

$$\begin{bmatrix} \mathbf{f}_X \\ \mathbf{f}_Y \end{bmatrix} \sim \mathcal{N}\left(\mathbf{0}, \begin{bmatrix} k(X, X) & k(X, Y) \\ k(Y, X) & k(Y, Y) \end{bmatrix}\right).$$

Zauważmy, iż jest to instancja modelu Gaussowskiego, więc rozkład warunkowy  $\mathbf{f}_Y \mid \mathbf{f}_X$  jest również rozkładem normalnym o parametrach

$$\begin{aligned} \boldsymbol{\mu} &= k(Y, X)k^{-1}(X, X)\mathbf{f}_X \\ \boldsymbol{\Sigma} &= k(Y, Y) - k(Y, X)k^{-1}(X, X)k(X, Y) \end{aligned}.$$

Dodatkową niepewność związaną z pomiarem wartości  $\mathbf{f}_X$  możemy uchwycić zmieniając postać jądra

$$k(\mathbf{x}, \mathbf{y}) \leftarrow k(\mathbf{x}, \mathbf{y}) + \mathcal{I}_X(\mathbf{x})\sigma^2\delta_{\mathbf{x}, \mathbf{y}},$$

gdzie  $\sigma$  jest hiper-parametrem określającym precyzję pomiaru. Oczywiście  $k$  jest dalej funkcją kowariancji, gdyż takie podstawienie powoduje jedynie dodanie dodatnich członów do pewnych elementów diagonalnych macierzy kowariancji, więc macierz ta jest nadal symetryczna i dodatnio określona. Wówczas rozkład predykcyjny ma parametry

$$\begin{aligned} \boldsymbol{\mu} &= k(Y, X) [k(X, X) + \sigma^2\mathbf{1}]^{-1} \mathbf{f}_X \\ \boldsymbol{\Sigma} &= k(Y, Y) - k(Y, X) [k(X, X) + \sigma^2\mathbf{1}]^{-1} k(X, Y) \end{aligned}.$$

Pozostaje jeszcze kwestia początkowej estymacji parametrów funkcji jądrowych dla zbioru danych  $D = (\mathbf{f}_X, X)$ . W łatwy i wydajny sposób możemy znaleźć estymaty MLE tych parametrów. Istotnie oznaczmy zbiór parametrów jądra przez  $\theta$ , wówczas

$$D \mid \theta \sim \mathcal{N}(\mathbf{0}, k(X, X; \theta))$$

czyli

$$\ell = -\log p(D \mid \theta) = \frac{1}{2} \log [\det(k(X, X; \theta) + \sigma^2\mathbf{1})] + \frac{1}{2} \mathbf{f}_X^\top [k(X, X; \theta) + \sigma^2\mathbf{1}]^{-1} \mathbf{f}_X.$$

Funkcję kosztu  $\ell$  minimalizujemy numerycznie, aby znaleźć estymatę MLE parametrów  $\theta$  funkcji jądrowej. Następnie parametry rozkładu predykcyjnego nad wartościami w nowych punktach znajdujemy korzystając ze wzorów dwie linijki wyżej.

## 2.9 Wieloklasowa regresja logistyczna

Założmy, iż modelujemy obserwacje postaci  $(t, \mathbf{x})$ , gdzie  $t \in \{\tau_1, \tau_2, \dots, \tau_s\}$  to etykieta określająca przynależność do jednej z  $s$  klas, a  $\mathbf{x} \in \mathbb{R}^n$  jest znanym (lub zadany) przez nas dokładnie wektorem cech obiektu dla których zaobserwowaną klasą jest  $t$ . Zakładamy ponadto, iż prawdopodobieństwo przynależności do klasy  $\tau_j$  (jednej z  $s$  klas) dla wektora cech  $\mathbf{x}$  ma postać tzw. funkcji softmax

$$\pi_j(\mathbf{x}) = \frac{1}{Z(\mathbf{x})} e^{\mathbf{w}_j^\top \mathbf{x}},$$

gdzie  $\mathbf{w}_j$  są estymowanymi przez nas parametrami. Ze względu na warunek unormowania musimy mieć

$$\sum_{j=1}^s \pi_j = 1,$$

skąd stała normalizacyjna  $Z(\mathbf{x})$  ma postać

$$Z(\mathbf{x}) = \sum_{j=1}^s e^{\mathbf{w}_j^\top \mathbf{x}}.$$

Uwaga, powyższy wzór nie może być stosowany bezpośrednio do obliczeń numerycznych przez niestabilność numeryczną (wartość funkcji wykładniczej może być ogromna). W praktyce wartość funkcji softmax dla argumentu  $\mathbf{z} = (z_1, \dots, z_n)$  obliczamy jako

$$z'_i := z_i - \max_{j=1, \dots, n} z_j$$

$$\text{softmax}(z_i) = \frac{e^{z'_i}}{\sum_{j=1}^n e^{z'_j}}.$$

Rozkład zmiennej losowej  $t$  jest w takim razie dyskretnym rozkładem wielopunktowym (z ang. *categorical distribution*) postaci

$$t \mid \mathbf{w}_1, \dots, \mathbf{w}_s \sim \text{Cat}(\pi_1(\mathbf{x}), \dots, \pi_s(\mathbf{x})).$$

Zauważmy, iż prawdopodobieństwo wylosowania etykiety  $t$  dla parametrów  $\mathbf{w}_j$  możemy zapisać jako

$$p(t \mid \mathbf{w}_1, \dots, \mathbf{w}_s) = \prod_{j=1}^s \pi_j(\mathbf{x})^{\delta(t, \tau_j)}.$$

Powiedzmy, że mamy obserwacje  $D = (t_1, \dots, t_m)$  dla znanych (lub zadanych) przez nas dokładnie wektorów cech  $(\mathbf{x}_1, \dots, \mathbf{x}_m)$ . Funkcja wiarygodności ma wówczas postać

$$p(D \mid \mathbf{w}_1, \dots, \mathbf{w}_s) = \prod_{i=1}^m p(t_i \mid \mathbf{w}_1, \dots, \mathbf{w}_s) = \prod_{i=1}^m \prod_{j=1}^s \pi_j(\mathbf{x}_i)^{\delta(t_i, \tau_j)}.$$

Jako prior dla parametrów  $\mathbf{w}_j$  przyjmiemy rozkład normalny z pewnym hiperparametrem  $\gamma$

$$\forall j \in \{1, \dots, s\} : \mathbf{w}_j \sim \mathcal{N}(\mathbf{0}, \gamma^{-1} \mathbf{1}).$$

W przypadku regresji logistycznej ograniczymy się do znalezienia estymaty MAP parametrów  $\mathbf{w}_j$  tak, aby w przyszłości do nowego wektora cech  $\mathbf{x}$  przyporządkować klasę o największym prawdopodobieństwie  $\pi_j(\mathbf{x})$ . Znalezienie estymaty MAP sprowadza się do znalezienia minimum zregulowanej funkcji kosztu

$$\begin{aligned} \ell^*(D \mid \mathbf{w}_1, \dots, \mathbf{w}_s) &= -\log[p(D \mid \mathbf{w}_1, \dots, \mathbf{w}_s)\pi(\mathbf{w}_1, \dots, \mathbf{w}_s)] \\ &= -\log \left[ \prod_{k=1}^s e^{-\frac{\gamma}{2} \mathbf{w}_k^\top \mathbf{w}_k} \prod_{i=1}^m \prod_{j=1}^s \pi_j(\mathbf{x}_i)^{\delta(t_i, \tau_j)} \right] \\ &= \frac{\gamma}{2} \sum_{j=1}^s \mathbf{w}_j^\top \mathbf{w}_j - \sum_{i=1}^m \sum_{j=1}^s \delta(t_i, \tau_j) \log \pi_j(\mathbf{x}_i). \end{aligned}$$

Niestety dla tak zdefiniowanej funkcji kosztu nie można znaleźć wzoru na minimum w postaci analitycznej, dlatego wykorzystamy numeryczny algorytm optymalizacji zwany spadkiem wzdłuż gradientu.

#### Algorytm spadku wzdłuż gradientu

1. Wybierz parametry początkowe  $\mathbf{x}_1^{(0)}, \dots, \mathbf{x}_m^{(0)}$
2. Powtarzaj

$$\begin{aligned} \mathbf{x}_1^{(t+1)} &= \mathbf{x}_1^{(t)} - \epsilon_1 \frac{\partial f}{\partial \mathbf{x}_1} \bigg|_{\mathbf{x}_1^{(t)}, \dots, \mathbf{x}_m^{(t)}} \\ &\vdots \\ \mathbf{x}_m^{(t+1)} &= \mathbf{x}_m^{(t)} - \epsilon_m \frac{\partial f}{\partial \mathbf{x}_m} \bigg|_{\mathbf{x}_1^{(t)}, \dots, \mathbf{x}_m^{(t)}} \end{aligned}$$

gdzie  $\epsilon_1, \dots, \epsilon_m$  to hiper-parametry zwane stałymi uczącymi (z ang. *learning rate*).

Zakładając  $\epsilon_1 = \dots = \epsilon_m = \epsilon$  i wprowadzając

$$\mathbf{X} := \begin{bmatrix} \mathbf{x}_1^\top \\ \vdots \\ \mathbf{x}_m^\top \end{bmatrix}, \quad \frac{\partial f}{\partial \mathbf{X}} := \begin{bmatrix} \frac{\partial f}{\partial \mathbf{x}_1}^\top \\ \vdots \\ \frac{\partial f}{\partial \mathbf{x}_m}^\top \end{bmatrix}$$

możemy zapisać powyższe równania w kompaktowej formie

$$\mathbf{X}^{(t+1)} = \mathbf{X}^{(t)} - \epsilon \frac{\partial f}{\partial \mathbf{X}} \Big|_{\mathbf{X}^{(t)}}.$$

Aby zminimalizować numerycznie funkcję kosztu  $\ell^*$  stosując metodę spadku wzdłuż gradientu musimy obliczyć pochodne funkcji kosztu po parametrach  $\mathbf{w}_j$

$$\frac{\partial \ell^*}{\partial \mathbf{w}_k} = \gamma \mathbf{w}_k - \sum_{i=1}^m \sum_{j=1}^s \delta(t_i, \tau_j) \frac{\partial}{\partial \mathbf{w}_k} \log \pi_j(\mathbf{x}_i),$$

ale

$$\begin{aligned} \frac{\partial}{\partial \mathbf{w}_k} \log \pi_j(\mathbf{x}_i) &= \frac{1}{\pi_j(\mathbf{x}_i)} \frac{Z(\mathbf{x}_i) \frac{\partial e^{\mathbf{x}_i^\top \mathbf{w}_j}}{\partial \mathbf{w}_k} - e^{\mathbf{x}_i^\top \mathbf{w}_j} \frac{\partial Z(\mathbf{x}_i)}{\partial \mathbf{w}_k}}{Z^2(\mathbf{x}_i)} \\ &= \frac{Z(\mathbf{x}_i)}{e^{\mathbf{x}_i^\top \mathbf{w}_j}} \frac{Z(\mathbf{x}_i) \mathbf{x}_i e^{\mathbf{x}_i^\top \mathbf{w}_k} \delta_{jk} - e^{\mathbf{x}_i^\top \mathbf{w}_j} e^{\mathbf{x}_i^\top \mathbf{w}_k} \mathbf{x}_i}{Z^2(\mathbf{x}_i)} \\ &= \mathbf{x}_i \delta_{jk} - \mathbf{x}_i \pi_k(\mathbf{x}_i) \end{aligned}$$

zatem

$$\frac{\partial \ell^*}{\partial \mathbf{w}_k} = \gamma \mathbf{w}_k - \sum_{i=1}^m \mathbf{x}_i \sum_{j=1}^s \delta(t_i, \tau_j) \delta_{jk} + \sum_{i=1}^m \mathbf{x}_i \pi_k(\mathbf{x}_i) \sum_{j=1}^s \delta(t_i, \tau_j).$$

Zauważmy jednak, iż

$$\sum_{j=1}^s \delta(t_i, \tau_j) = 1, \quad \sum_{j=1}^s \delta(t_i, \tau_j) \delta_{jk} = \delta(t_i, \tau_k),$$

zatem ostatecznie

$$\frac{\partial \ell^*}{\partial \mathbf{w}_k} = \gamma \mathbf{w}_k + \sum_{i=1}^m \mathbf{x}_i [\pi_k(\mathbf{x}_i) - \delta(t_i, \tau_k)].$$

Wprowadzając macierze

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \vdots \\ \mathbf{x}_m^\top \end{bmatrix}, \quad \mathbf{W} = \begin{bmatrix} \mathbf{w}_1^\top \\ \vdots \\ \mathbf{w}_s^\top \end{bmatrix},$$

$$\mathbf{S} = \begin{bmatrix} \pi_1(\mathbf{x}_1) & \cdots & \pi_s(\mathbf{x}_1) \\ \vdots & \ddots & \vdots \\ \pi_1(\mathbf{x}_m) & \cdots & \pi_s(\mathbf{x}_m) \end{bmatrix}, \quad \mathbf{T} = \begin{bmatrix} \delta(t_1, \tau_1) & \cdots & \delta(t_1, \tau_s) \\ \vdots & \ddots & \vdots \\ \delta(t_m, \tau_1) & \cdots & \delta(t_m, \tau_s) \end{bmatrix}$$

możemy w takim razie zapisać zdefiniowaną wyżej macierz pochodnych wymaganych do algorytmu spadku wzdłuż gradient w kompaktowej formie jako

$$\frac{\partial \ell^*}{\partial \mathbf{W}} = (\mathbf{S} - \mathbf{T})^\top \mathbf{X}.$$

Zauważmy, iż zregularyzowana funkcja kosztu rośnie wraz ze wzrostem liczby obserwacji  $m$ . Wynika z tego, iż stała ucząca musi być zależna od liczby przykładów. Możemy na przykład stwierdzić, iż  $\epsilon \leftarrow m^{-1}\epsilon$  i wówczas minimalizujemy tak naprawdę średni koszt  $\ell^*/m$ .

## 2.10 Wnioskowanie metodami Monte Carlo

Całe wnioskowanie Bayesowskie opiera się na wyznaczaniu rozkładów a posteriori, które wyrażają naszą wiedzę o estymowanym parametrze. Do tej pory rozważaliśmy modele Bayesowskie dla których prior i wiarygodność były dane przez rozkłady normalne. Dzięki temu mogliśmy wyprowadzić analityczne wzory na parametry rozkładu a posteriori, który również był rozkładem normalnym. Dla wielu interesujących modeli nie jesteśmy jednak w stanie tego zrobić (np. w zagadnieniu regresji logistycznej ograniczyliśmy się jedynie do estymaty punktowej), gdyż obliczenie stałej normalizującej dla rozkładu  $p(\theta | D)$  może wymagać obliczenia całki, której nie jesteśmy w stanie wyrazić w sposób jawny lub sumy po wykładniczo wielu elementach. Wnioskowanie Bayesowskie można jednak prowadzić w modelach, w których nie dysponujemy jawnym wzorem na gęstość prawdopodobieństwa rozkładu a posteriori. Okazuje się, iż do generowania próbek z rozkładu  $p(\theta | D)$  wystarcza znajomość tego rozkładu z dokładnością do stałej normalizującej, a zatem wystarczy znać rozkład łączny  $p(\theta, D) = p(D | \theta)\pi(\theta)$ . Generowanie próbek z kolei wystarcza natomiast, na mocy silnego prawa wielkich liczb, do szacowania wartości średnich dowolnych funkcji estymowanego parametru  $\theta$ . Przypomnijmy, iż na mocy silnego prawa wielkich liczb ciąg średnich częściowych  $(\bar{X}_n)$  ciągu zmiennych losowych  $(X_n)$  i.i.d. z rozkładu  $X \sim \mathcal{D}$  jest zbieżny z prawdopodobieństwem 1 do wartości oczekiwanej  $\mathbb{E}[X]$  tj.

$$P\left(\lim_{n \rightarrow \infty} \bar{X}_n = \mathbb{E}[X]\right) = 1.$$

Wartość oczekiwaną  $\mathbb{E}[X]$  możemy zatem przybliżyć średnią  $\bar{X}_n$  z dużej ilości próbek.

Wnioskowanie Monte Carlo pozwala nam szacować różne wielkości w tzw. hierarchicznych modelach Bayesowskich (z ang. *Bayesian hierarchical modeling*). Rozważmy jeszcze raz przykład regresji liniowej w ujęciu Bayesowskim, ale rozważmy teraz model postaci

$$\begin{aligned}\sigma^2 &\sim \mathcal{D}(\lambda) \\ \mathbf{w} &\sim \mathcal{N}(\boldsymbol{\mu}_0, \boldsymbol{\Sigma}_0) \\ y \mid \mathbf{w}, \sigma^2 &\sim \mathcal{N}(\mathbf{w}^\top \mathbf{x}, \sigma^2)\end{aligned},$$

gdzie  $\lambda, \boldsymbol{\mu}_0, \boldsymbol{\Sigma}_0$  są pewnymi hiper-parametrami. Dla takiego modelu nie możemy w ogólności znaleźć jawnej postaci rozkładu a posteriori. Jeśli jednak umiemy generować próbki z rozkładu łącznego

$$Z \cdot p(\mathbf{w}, \sigma^2 \mid D) = p(D, \mathbf{w}, \sigma^2) = p(D \mid \mathbf{w}, \sigma^2) \pi(\mathbf{w}) \pi(\sigma^2)$$

to wszystkie interesujące wielkości możemy oszacować jako odpowiednie średnie. Pozostaje pytanie w jaki sposób generować próbki ze skomplikowanych rozkładów prawdopodobieństwa, których gęstości znamy jedynie z dokładnością do stałej normalizującej. Poniżej przedstawimy dwa algorytmy próbkowania: algorytm IS oraz Metropolisa–Hastingsa będący szczególną realizacją całej rodziny algorytmów próbkowania zwanych Markov Chain Monte Carlo (MCMC).

### 2.10.1 Algorytm Importance Sampling (IS)

Załóżmy, iż chcemy obliczyć wartość oczekiwaną pewnej funkcji zmiennej losowej  $\mathbf{x}$  względem skomplikowanego rozkładu prawdopodobieństwa  $p(\mathbf{x})$ , który znamy jedynie z dokładnością do stałej normalizującej

$$p(\mathbf{x}) = \frac{1}{Z_p} \tilde{p}(\mathbf{x})$$

tj. szukamy

$$\mathbb{E}_p[f(\mathbf{x})] = \int f(\mathbf{x}) p(\mathbf{x}) d^n \mathbf{x}.$$

Jeśli umiemy generować próbki  $\mathbf{x}$  z innego (prostsze) rozkładu  $q(\mathbf{x})$ , który nazywamy rozkładem proponującym kandydatów (z ang. *proposal distribution*) to możemy zapisać

$$\begin{aligned}\mathbb{E}_p[f(\mathbf{x})] &= \int_{\mathbb{R}^n} f(\mathbf{x}) p(\mathbf{x}) d^n \mathbf{x} = \int_{\mathbb{R}^n} f(\mathbf{x}) \frac{p(\mathbf{x})}{q(\mathbf{x})} q(\mathbf{x}) d^n \mathbf{x} \\ &= \mathbb{E}_q \left[ f(\mathbf{x}) \frac{p(\mathbf{x})}{q(\mathbf{x})} \right] = \frac{Z_q}{Z_p} \mathbb{E}_q \left[ f(\mathbf{x}) \frac{\tilde{p}(\mathbf{x})}{\tilde{q}(\mathbf{x})} \right].\end{aligned}$$



Zakładamy tutaj, iż nośnik rozkładu  $p$  zawiera się w nośniku  $q$  tj.  $\text{supp } p \subseteq \text{supp } q$ . Stosunek stałych  $Z_p/Z_q$  również możemy oszacować z próbek z  $q$ , gdyż mamy

$$Z_p = \int_{\mathbb{R}^n} \tilde{p}(\mathbf{x}) d^n \mathbf{x} = Z_q \int_{\mathbb{R}^n} \frac{\tilde{p}(\mathbf{x})}{\tilde{q}(\mathbf{x})} q(\mathbf{x}) d^n \mathbf{x} = Z_q \mathbb{E}_q \left[ \frac{\tilde{p}(\mathbf{x})}{\tilde{q}(\mathbf{x})} \right],$$

skąd ostatecznie

$$\mathbb{E}_p[f(\mathbf{x})] = \frac{\mathbb{E}_q \left[ f(\mathbf{x}) \frac{\tilde{p}(\mathbf{x})}{\tilde{q}(\mathbf{x})} \right]}{\mathbb{E}_q \left[ \frac{\tilde{p}(\mathbf{x})}{\tilde{q}(\mathbf{x})} \right]}.$$

Jeśli z rozkładu  $q$  wygenerowaliśmy próbki  $X = \{\mathbf{x}_1, \dots, \mathbf{x}_m\}$  to na mocy silnego prawa wielkich liczb mamy

$$\mathbb{E}_p[f(\mathbf{x})] \approx \frac{\sum_{i=1}^m f(\mathbf{x}_i) \frac{\tilde{p}(\mathbf{x}_i)}{\tilde{q}(\mathbf{x}_i)}}{\sum_{i=1}^m \frac{\tilde{p}(\mathbf{x}_i)}{\tilde{q}(\mathbf{x}_i)}} = \sum_{i=1}^m \lambda_i f(\mathbf{x}_i),$$

gdzie

$$\lambda_i = \frac{\tilde{p}(\mathbf{x}_i)/\tilde{q}(\mathbf{x}_i)}{\sum_{j=1}^m \tilde{p}(\mathbf{x}_j)/\tilde{q}(\mathbf{x}_j)}.$$

Algorytm Importance Sampling jest prostym algorytmem Monte Carlo, który ma jeden zasadniczy problem. W jaki sposób mamy wybrać rozkład proponujący kandydatów  $q$ ? Pewną odpowiedź na to pytanie sugeruje analiza wariancji statystyki

$$\bar{f}_m(\mathbf{x}_1, \dots, \mathbf{x}_m) = \frac{1}{m} \sum_{i=1}^m \frac{f(\mathbf{x}_i) p(\mathbf{x}_i)}{q(\mathbf{x}_i)}$$

dla  $\mathbf{x}_i \sim q$  i zakładając dla uproszczenia, iż  $f$  jest funkcją skalarną mamy

$$\text{Var}[\bar{f}_m] = \frac{1}{m} \text{Var}_q \left[ f(\mathbf{x}) \frac{p(\mathbf{x})}{q(\mathbf{x})} \right] = \frac{1}{m} \int_{\mathbb{R}^n} \frac{(f(\mathbf{x}) p(\mathbf{x}) - \mu_f q(\mathbf{x}))^2}{q(\mathbf{x})} d^n \mathbf{x}.$$

Chcemy oczywiście, aby wariancja była jak najmniejsza, gdyż wówczas mała liczba próbek da dobre przybliżenie wartości oczekiwanej. Rozkład proponujący kandydatów powinien być zatem proporcjonalny do  $f(\mathbf{x})p(\mathbf{x})$ , co może być trudne do praktycznego zrealizowania.

### 2.10.2 Algorytm Metropolisa–Hastingsa

Cała klasa algorytmów próbkowania MCMC opiera się na idei wyrażenia generowania próbek jako ewolucji pewnego łańcucha Markowa. Łańcuchem Markowa

nazywamy ciąg zmiennych losowych  $(X_t)$  o wartościach w  $\mathbb{R}^n$  taki, że spełnione jest kryterium Markowa

$$\forall A \subset \mathbb{R}^n : P(X_t \in A \mid X_{t-1} = \mathbf{x}_{t-1}, \dots, X_0 = \mathbf{x}_0) = P(X_t \in A \mid X_{t-1} = \mathbf{x}_{t-1}) .$$

Elementy ciągu nazywamy stanami łańcucha Markowa. Dany łańcuch jest zadany jednoznacznie przez podanie gęstości prawdopodobieństwa przejścia łańcucha ze stanu  $\mathbf{x} \rightarrow \mathbf{y}$ , którą będziemy oznaczać przez  $\pi(\mathbf{y} \mid \mathbf{x})$  (zakładamy, iż prawdopodobieństwo przejścia jest niezależne od chwili  $t$  – łańcuch taki nazywamy jednorodnym). Funkcja  $\pi$  spełnia oczywiście warunek unormowania

$$\int_{\mathbb{R}^n} \pi(\mathbf{y} \mid \mathbf{x}) d^n \mathbf{y} ,$$

istotnie prawdopodobieństwo przejścia gdziekolwiek ze stanu  $\mathbf{x}$  jest równe 1. Będziemy zakładać dodatkowo, iż  $\forall \mathbf{x}, \mathbf{y} \in \mathbb{R}^n : \pi(\mathbf{y} \mid \mathbf{x}) > 0$ . Rozkład  $p(\mathbf{x})$  łańcucha Markowa (tj. rozkład prawdopodobieństwa z którego losujemy stan łańcucha w danej chwili  $t$ ) z daną funkcją przejścia  $\pi$  nazwiemy rozkładem stacjonarnym tego łańcucha iff

$$p(\mathbf{y}) = \int_{\mathbb{R}^n} \pi(\mathbf{y} \mid \mathbf{x}) p(\mathbf{x}) d^n \mathbf{x} .$$

Rozkład stacjonarny danego łańcucha oznaczmy przez  $p^*(\mathbf{x})$ . Zauważmy, iż jeśli stan początkowy łańcucha  $X_0$  pochodzi z rozkładu stacjonarnego  $p^*$  to każdy kolejny stan  $X_t$  również pochodzi z rozkładu stacjonarnego. Jeśli z kolei stan początkowy pochodzi z jakiegoś innego rozkładu  $p_0$  to rozkład łańcucha w chwili  $t$  jest dany przez relację rekurencyjną

$$p_t(\mathbf{y}) = \int_{\mathbb{R}^n} \pi(\mathbf{y} \mid \mathbf{x}) p_{t-1}(\mathbf{x}) d^n \mathbf{x} , \quad \text{dla } t > 1 .$$

Rozkładem granicznym łańcucha Markowa nazwiemy granicę w sensie zbieżności punktowej

$$\lim_{t \rightarrow \infty} p_t(\mathbf{x}) .$$

Przy podanych wyżej założeniach istnieje twierdzenie, które mówi iż taki łańcuch Markowa posiada jednoznaczny rozkład stacjonarny tożsamy z rozkładem granicznym. Ponadto warunkiem wystarczającym, aby dany rozkład  $p(\mathbf{x})$  był rozkładem stacjonarnym łańcucha Markowa jest

$$\forall \mathbf{x}, \mathbf{y} \in \mathbb{R}^n : \pi(\mathbf{y} \mid \mathbf{x}) p(\mathbf{x}) = \pi(\mathbf{x} \mid \mathbf{y}) p(\mathbf{y}) ,$$

co wynika z scałkowania powyższego równania

$$\int_{\mathbb{R}^n} \pi(\mathbf{y} | \mathbf{x}) p(\mathbf{x}) d^n \mathbf{x} = \int_{\mathbb{R}^n} \pi(\mathbf{x} | \mathbf{y}) p(\mathbf{y}) d^n \mathbf{x} = p(\mathbf{y}) \int_{\mathbb{R}^n} \pi(\mathbf{x} | \mathbf{y}) d^n \mathbf{x} = p(\mathbf{y}).$$

Kryterium to nazywamy kryterium lokalnego balansu (z ang. *detailed balance condition*).

Podstawowa idea wykorzystania łańcuchów Markowa do generowania próbek ze skomplikowanego rozkładu  $p$  jest więc następująca: tworzymy łańcuch Markowa opisany powyżej, dla którego  $p$  jest rozkładem stacjonarnym, wówczas rozpoczynając w dowolnym dopuszczalnym stanie początkowym  $X_0$  po wykonaniu dużej liczby kroków (etap ten nazywamy okresem przejściowym z ang. *burn-in period*) stan  $X_t$  (dla  $t \gg 1$ ) tego łańcucha będzie w przybliżeniu pochodził z rozkładu granicznego  $p$  (nie jest jednak prosto stwierdzić po jak długim okresie przejściowym przybliżenie to jest wystarczająco dobre). Aby otrzymać z takiej procedury próbki prawdziwie i.i.d. każda z próbek musiałaby pochodzić z ponownego uruchomienia takiego łańcucha. Oczywiście jest to nieefektywne, więc w praktyce generujemy próbki z jednego łańcucha po prostu odrzucając pewne z nich tak aby uniknąć znaczących korelacji.

Pozostaje pytanie jak skonstruować funkcję przejścia  $\pi(\mathbf{y} | \mathbf{x})$  dla danego rozkładu granicznego  $p(\mathbf{x})$ . Podstawową konstrukcję podaje algorytm Metropolis–Hastingsa:

1. Jako stan początkowy przyjmij dowolną dopuszczalną wartość  $\mathbf{x} \leftarrow \mathbf{x}_0$ .
2. Powtarzaj:
  - (a) Będąc w aktualnym stanie  $\mathbf{x}$  z prostego rozkładu proponującego kandydatów  $q(\mathbf{y} | \mathbf{x})$  wylosuj kandydata  $\mathbf{y}$  na wartość łańcucha w kolejnym stanie.
  - (b) Z prawdopodobieństwem

$$r(\mathbf{y} | \mathbf{x}) = \min \left\{ 1, \frac{p(\mathbf{y})q(\mathbf{x} | \mathbf{y})}{p(\mathbf{x})q(\mathbf{y} | \mathbf{x})} \right\}$$

zaakceptuj kandydata jako nowy stan i przejdź do stanu  $\mathbf{y}$ . W przeciwnym razie pozostać w stanie  $\mathbf{x}$

Funkcja przejścia ma zatem postać

$$\pi_{\text{MH}}(\mathbf{y} | \mathbf{x}) = q(\mathbf{y} | \mathbf{x}) r(\mathbf{y} | \mathbf{x}).$$

Pozostaje tylko wykazać, iż spełnione jest kryterium lokalnego balansu. Istotnie mamy

$$\begin{aligned}\pi_{\text{MH}}(\mathbf{y} \mid \mathbf{x})p(\mathbf{x}) &= \min \{q(\mathbf{y} \mid \mathbf{x})p(\mathbf{x}), q(\mathbf{x} \mid \mathbf{y})p(\mathbf{y})\} \\ \pi_{\text{MH}}(\mathbf{x} \mid \mathbf{y})p(\mathbf{y}) &= \min \{q(\mathbf{x} \mid \mathbf{y})p(\mathbf{y}), q(\mathbf{y} \mid \mathbf{x})p(\mathbf{x})\}\end{aligned}\quad ,$$

skąd  $\pi_{\text{MH}}(\mathbf{y} \mid \mathbf{x})p(\mathbf{x}) = \pi_{\text{MH}}(\mathbf{x} \mid \mathbf{y})p(\mathbf{y})$ . Zauważmy, iż nie musimy znać  $p(\mathbf{x})$  z dokładnością do stałej normalizującej, gdyż

$$\frac{p(\mathbf{y})}{p(\mathbf{x})} = \frac{\tilde{p}(\mathbf{y})/Z_p}{\tilde{p}(\mathbf{x})/Z_p} = \frac{\tilde{p}(\mathbf{y})}{\tilde{p}(\mathbf{x})}.$$

Poza algorytmem Metropolis–Hastingsa jest wiele innych algorytmów z rodziny MCMC. Większość z nich implementuje konkretny sposób generowania (zostawiając resztę struktury) tak, aby zmniejszyć korelację po okresie przejściowym i przyspieszyć zbieżność. Standardowo wykorzystywanymi algorytmami z tej klasy są algorytmy HMC (*Hamiltonian Monte Carlo*) oraz NUTS (*No U-Turn Sampler*).

---

## 3 Sieci neuronowe

### 3.1 Tensory

W przypadku uczenia maszynowego  $k$ -tensor będziemy utożsamiali z odwzorowaniem

$$X : \mathbb{N}^k \supset I \mapsto \mathbb{K},$$

gdzie  $\mathbb{K}$  jest pewnym ciałem, a  $I$  jest pewnym spójnym zbiorem wielowskaźników tj. zakładamy, iż

$$\forall \alpha \in \{1, \dots, k\} : i_\alpha > 0 \wedge (i_1, \dots, i_\alpha, \dots, i_k) \in I \implies (i_1, \dots, i_\alpha - 1, \dots, i_k) \in I.$$

Jest to zatem po prostu wielowymiarowa tablica, której elementy są skalarami. My będziemy zawsze przyjmować  $\mathbb{K} = \mathbb{R}$ . Miejsce  $\alpha$  wielowskaźnika będziemy nazywali osią. Wartość elementu tensora  $X$  pod wielowskaźnikiem  $(i_1, \dots, i_k)$  będziemy oznaczać  $X_{i_1, \dots, i_k}$ . Czasami będziemy utożsamiać zapis  $X_{i_1, \dots, i_k}$  z odwzorowaniem  $X$ , a nie z jego wartością dla argumentu  $(i_1, \dots, i_k)$ , aby podkreślić jakie argumenty przyjmuje. Jest to tożsame z częstym w matematyce oznaczaniem funkcji jako  $f(x)$  podczas, gdy funkcją jest  $f$ , a  $f(x)$  to jej wartość dla argumentu  $x$ .

Dla tensora  $X : \mathbb{N}^k \supset I \mapsto \mathbb{R}$  definiujemy tzw. operator kształtu (z ang. *shape operator*)  $\mathfrak{m}$

$$\mathfrak{m}(X) := (\mathfrak{m}_1(X), \dots, \mathfrak{m}_k(X)), \quad \mathfrak{m}_\alpha(X) := \text{liczba elementów } X \text{ wzdłuż osi } \alpha.$$

Operator kształtu zwraca wektor liczb naturalnych zawierający uogólnienie liczb kolumn/wierszy dla macierzy. W szczególności dla tablicy jednowymiarowej (tj. 1-tensora)  $T$  zawierającej  $n$  elementów będziemy stosowali zapis  $\mathfrak{m}(T) = (n, )$ .

Zbiór wszystkich tensorów danego kształtu  $\mathfrak{m} = (n_1, \dots, n_k)$  o elementach rzeczywistych będziemy oznaczać przez  $\mathbb{T}_{n_1, \dots, n_k}(\mathbb{R}) = \mathbb{T}_{\mathfrak{m}}(\mathbb{R})$ . Jeśli będzie to oczywiste z kontekstu (u nas zawsze) to pominiemy człon w nawiasach pisząc po prostu  $\mathbb{T}_{n_1, \dots, n_k} = \mathbb{T}_{\mathfrak{m}}$ . Odwzorowanie  $F$  o argumentach i wartościach tensorowych zdefiniujemy jako  $F : \mathbb{T}_{\mathfrak{m}_1} \mapsto \mathbb{T}_{\mathfrak{m}_2}$ . Wówczas wartość tego odwzorowania dla argumentu  $X$  ( $\mathfrak{m}(X) = \mathfrak{m}_1$ ) tj.  $F(X)$  jest tensorem ( $\mathfrak{m}(F(X)) = \mathfrak{m}_2$ ). Ponadto będziemy utożsamiać zapis  $(F(X))_{i_1, \dots, i_k}$  z  $F_{i_1, \dots, i_k}(X)$ .

W wyrażeniach zawierających iloczyny postaci

$$X_{i_1, \dots, i_p} Y_{j_1, \dots, j_q} Z_{k_1, \dots, k_r} \dots$$

stosujemy (uproszczoną) konwencję sumacyjną Einsteina tj. dla każdego powtórzonego indeksu w takim wyrażeniu należy przed wyrażenie postawić znak sumy

po tym indeksie (tzw. *indeks sumacyjny*), przy czym dla zwiększenia przejrzystości zapisu nie piszemy znaków sumy explicite. Oznacza to w szczególności, iż możemy łatwo definiować nowe tensory jako odpowiednie iloczyny np. iloczyn macierzy  $A \in \mathbb{T}_{n,m}, B \in \mathbb{T}_{m,l}$  możemy zapisać jako

$$C_{ik} = A_{ij}B_{jk}.$$

wyrażenie to definiuje nowy tensor  $C \in \mathbb{T}_{n,l}$ , którego elementy są dane poprzez sumę iloczynów odpowiednich elementów  $A, B$ . Zauważmy jednakże, iż ponieważ nie wykorzystujemy wskaźników dolnych i górnych, więc jednakowo poprawnymi wyrażeniami są  $A_{ij}X_i$  oraz  $A_{ij}X_j$  chociaż w ogólności  $A_{ij}X_i \neq A_{ij}X_j$ . Dodatkowo dla funkcji  $f : \mathbb{R} \mapsto \mathbb{R}$  zapis postaci  $Y_{ijk..} = f(X_{ijk..})$  dla dowolnego tensora  $X$  definiuje tensor  $Y$ , którego wartości są wartościami funkcji  $f$  dla odpowiednich wartości tensora  $X$ . Dodatkowo jeśli  $f : \mathbb{R} \mapsto \mathbb{R}$ , a  $F : \mathbb{T}_{\mathbb{M}_1} \mapsto \mathbb{T}_{\mathbb{M}_2}$  to przez zapis  $Y = (f \circ F)(X)$  będziemy rozumieć

$$Y_{ijk..} = f(F_{ijk..}(X)).$$

Ostatnim elementem notacji, który będzie nam potrzebny jest tzw. operator zakresu (z ang. *range operator*). Przez zapis

$$X_{\mu_1:\nu_1, \dots, \mu_k:\nu_k}$$

będziemy rozumieć  $k$ -tensor będący podtensorem  $X$  powstałym przez wybranie odpowiednich zakresów  $\mu_\alpha : \nu_\alpha$  osi  $\alpha$ . Wartości tego podtensora będziemy oznaczać jako  $(X_{\mu_1:\nu_1, \dots, \mu_k:\nu_k})_{i_1, \dots, i_k}$ . Jeśli dla danej osi wybieramy cały zakres to będziemy pisali sam znak „:”. Jeśli będziemy chcieli wybrać co  $\delta$  element z zakresu od  $\mu : \nu$  zaczynając od pierwszego to zapiszemy to jako  $\mu : \nu : \delta$ .

## 3.2 Neuron

Podstawowym elementem każdej sieci neuronowej jest pojedynczy neuron, który możemy traktować jako odwzorowanie  $y : \mathbb{T}_n \mapsto \mathbb{R}$  będące złożeniem pewnego odwzorowania nieliniowego  $\sigma : \mathbb{R} \mapsto \mathbb{R}$  z odwzorowaniem afinicznym

$$\begin{aligned} y &: \mathbb{T}_n \mapsto \mathbb{R} \\ y &= \sigma(W_i X_i + b) \end{aligned}$$

W praktyce jako funkcji aktywacji  $\sigma$  (*activation function*) najczęściej używamy funkcji ReLU, GELU lub funkcji sigmoidalnych:


$$\text{ReLU}(x) := \max(0, x), \quad \text{GELU}(x) := x\Phi(x),$$

gdzie  $\Phi(x)$  to dystrybuenta standardowego rozkładu normalnego. Pojedyncze neurony są następnie łączone w sieci w określony sposób tworząc daną architekturę sieci neuronowej.


### 3.3 Sieć MLP

Opis sieci neuronowych zaczniemy od architektury MLP (z ang. *Multilayer Perceptron*). Sieć MLP składa się z równoległych warstw neuronów, przy czym połączenia występują tylko między neuronami w sąsiednich warstwach i nie ma połączeń między neuronami w obrębie jednej warstwy. Pierwszą warstwę sieci nazywamy warstwą wejściową (z ang. *input layer*), ostatnią – warstwą wyjściową (z ang. *output layer*), a pozostałe nazywamy warstwami ukrytymi (z ang. *hidden layers*).

Zauważmy, iż opisane wcześniej modele regresji liniowej i wieloklasowej regresji logistycznej są przykładami najprostszych sieci MLP bez żadnych warstw ukrytych. Ich graficzne reprezentacje jako sieci MLP zamieszczono na Rysunku 1a i 1b.



(a) Graficzna reprezentacja regresji liniowej jako najprostszej sieci MLP



(b) Graficzna reprezentacja wieloklasowej regresji logistycznej jako najprostszej sieci MLP

Zauważmy, iż wyjściem sieci są parametry docelowego rozkładu prawdopodobieństwa nad obserwacjami tj. odpowiednio wartość oczekiwana  $\mu$  w przypadku

regresji liniowej i prawdopodobieństwa  $\pi_i$  każdej z klas rozkładu kategorialnego w przypadku regresji logistycznej. W przypadku regresji liniowej funkcja aktywacji neuronu w warstwie wyjściowej to po prostu funkcja identycznościowa, natomiast w przypadku regresji logistycznej jest to funkcja soft-max.

Przejdźmy teraz do matematycznego opisu architektury MLP. Załóżmy, iż sieć składa się z  $H+2$  warstw ( $H$  warstw ukrytych) o liczbach neuronów  $N_{in} = N_0$  (warstwa wejściowa),  $N_1, \dots, N_H$  (warstwy ukryte),  $N_{out} = N_{H+1}$  (warstwa wyjściowa). Jeśli  $X \in \mathbb{T}_{N_{h-1}}$  jest wejściem  $h$ -tej warstwy ukrytej to jej wyjście  $Y^h \in \mathbb{T}_{N_h}$  jest dane przez

$$Y_i^h = \sigma(W_{ij}^h X_j + B_i^h) \iff Y = (\sigma \circ L^h)(X),$$

gdzie  $W_{ij}^h$  jest macierzą wag w  $h$ -tej warstwie ukrytej, a  $B_i^h$  jest wektorem obciążeń (z ang. *bias*) w tej warstwie (indeks górny nie jest potęgą tylko numeruje warstwy). Zdefiniowaliśmy tutaj odwzorowanie

$$\begin{aligned} L^h : \mathbb{T}_{N_{h-1}} &\mapsto \mathbb{T}_{N_h} \\ L_i^h(X) &= W_{ij}^h X_j + B_i^h \end{aligned} \quad .$$

Bez straty ogólności zakładamy, iż wyjście warstwy wyjściowej jest po prostu obciążoną kombinacją liniową wejść bez żadnej funkcji nieliniowej. Wyjście z sieci MLP jest zatem dane przez następujące złożenie

$$\begin{aligned} F : \mathbb{T}_{N_{in}} &\mapsto \mathbb{T}_{N_{out}} \\ F(X) &= (L^{H+1} \circ \sigma \circ L^H \circ \dots \circ \sigma \circ L^2 \circ \sigma \circ L^1)(X) \end{aligned} \quad .$$

W takiej postaci sieć MLP przetwarza pojedynczo każdy wektor  $X_j$  należący do zbioru danych  $\{(Y_i^k, X_j^k) \mid k \in \{1, \dots, D\}\}$ . Możemy jednak rozszerzyć odwzorowanie  $F$  w taki sposób, aby sieć przetwarzała od razu tensor  $X_{jk}$  zawierający wszystkie przykłady ze zbioru uczącego

$$\begin{aligned} F : \mathbb{T}_{N_{in}, D} &\mapsto \mathbb{T}_{N_{out}, D} \\ F(X) &= (L^{H+1} \circ \sigma \circ L^H \circ \dots \circ \sigma \circ L^2 \circ \sigma \circ L^1)(X) \end{aligned} \quad .$$

$$\begin{aligned} L^h : \mathbb{T}_{N_{h-1}, D} &\mapsto \mathbb{T}_{N_h, D} \\ L_{ik}^h(X) &= W_{ij}^h X_{jk} + B_i^h I_k \end{aligned}$$

gdzie  $\mathbb{I}_I = \{1\}$ .

Wyjście z sieci neuronowej będziemy wykorzystywać przy tworzeniu modeli statystycznych w taki sam sposób jak w modelach płytkich (regresja liniowa, regresja softmax) używaliśmy kombinacji liniowej wektora obserwacji z wektorem wag  $\mathbf{w}^\top \mathbf{x}$ . Uczenie parametrów  $W_{ij}^h, B_i^h$  będzie zatem polegało na znalezieniu ich



estymaty punktowej MLE dla danego modelu statystycznego. Będziemy zatem minimalizować pewien funkcjonal  $J$  (funkcję kosztu) o postaci danej przez zane-gowaną logarytmiczną funkcję wiarygodności. Przykładowo dla regresji użyjemy funkcjonau kwadratowego

$$J[F] = \frac{1}{2} (F_{ij}(X) - Y_{ij})^2 ,$$

gdzie  $(Y_{ik}, X_{jk})$  jest zbiorem danych treningowych. Natomiast w przypadku wielo-klasowej regresji logistycznej jako funkcjonal przyjmujemy entropię krzyżową

$$J[F] = -T_{ik} \log \Pi_{ik} , \quad \Pi_{ik} = \frac{\exp \{F_{ik}(X)\}}{I_j \exp \{F_{jk}(X)\}} ,$$

gdzie  $T_{:,k}$  jest wektorem w postaci *one-hot encoding* prawidłowej klasy dla wektora zmiennych objaśniających  $X_{:,k}$  ze zbioru danych treningowych.

### 3.4 Wsteczna propagacja błędu

W przypadku algorytmów minimalizacji takich jak spadek wzdłuż gradientu mu-simy znać wartości pochodnych funkcji kosztu po parametrach modelu. Wyzna-czymy teraz te pochodne dla wag w sieci MLP. Niech  $Y_{ab}^h = \sigma(L_{ab}^h)$ , wówczas  $L_{ab}^h = W_{ac}^h Y_{cb}^{h-1} + B_a^h I_b$ , przy czym zakładamy  $Y^0 = X$ . Mamy odpowiednio

$$\begin{aligned} \frac{\partial L_{ab}^h}{\partial W_{ef}^h} &= Y_{cb}^{h-1} \delta_{ae} \delta_{cf} = Y_{fb}^{h-1} \delta_{ae} \\ \frac{\partial L_{ab}^h}{\partial Y_{ef}^{h-1}} &= W_{ac}^h \delta_{ce} \delta_{fb} = W_{ae}^h \delta_{fb} \quad . \\ \frac{\partial Y_{ab}^h}{\partial L_{cd}^h} &= \sigma'(L_{ab}^h) \delta_{ac} \delta_{bd} \end{aligned}$$

Jednocześnie zauważmy, że

$$\frac{\partial J}{\partial W_{ab}^h} = \left( \frac{\partial J}{\partial F_{cd}} \frac{\partial F_{cd}}{\partial L_{ef}^{H+1}} \right) \left( \frac{\partial L_{ef}^{H+1}}{\partial Y_{ij}^H} \frac{\partial Y_{ij}^H}{\partial L_{kl}^H} \right) \left( \frac{\partial L_{kl}^H}{\partial Y_{mn}^{H-1}} \frac{\partial Y_{mn}^{H-1}}{\partial L_{pq}^{H-1}} \right) \left( \dots \right) \frac{\partial L_{xy}^h}{\partial W_{ab}^h} .$$

Pochodne możemy obliczać zatem iteracyjnie jako

$$\frac{\partial J}{\partial W_{ab}^h} = \Delta_{ij}^h \frac{\partial L_{ij}^h}{\partial W_{ab}^h} = \Delta_{ij}^h Y_{bj}^{h-1} \delta_{ai} = \boxed{\Delta_{aj}^h Y_{bj}^{h-1}} ,$$

gdzie  $\Delta_{ij}^h$  wyznaczamy iteracyjnie jako

$$\Delta_{ij}^{H+1} = \frac{\partial J}{\partial F_{kl}} \frac{\partial F_{kl}}{\partial L_{ij}^{H+1}} = \frac{\partial J}{\partial F_{kl}} \delta_{ik} \delta_{jl} = \boxed{\frac{\partial J}{\partial F_{ij}}}$$

$$\Delta_{ij}^h = \Delta_{kl}^{h+1} \frac{\partial L_{kl}^{h+1}}{\partial Y_{mn}^h} \frac{\partial Y_{mn}^h}{\partial L_{ij}^h} = \Delta_{kl}^{h+1} W_{km}^{h+1} \delta_{ln} \sigma'(L_{mn}^h) \delta_{mi} \delta_{nj} = \boxed{\Delta_{kj}^{h+1} W_{ki}^{h+1} \sigma'(L_{ij}^h)}$$

Zauważmy również, iż wzór na pochodną funkcji kosztu  $J$  po parametrach  $B_a^h$  możemy od razu zapisać jako

$$\frac{\partial J}{\partial B_a^h} = \Delta_{aj}^h I_j.$$

Możemy zatem zapisać algorytm obliczania pochodnych funkcji kosztu po parametrach sieci neuronowej zwany algorytmem wstecznej propagacji błędów (z ang. *error backpropagation*)

#### Algorytm wstecznej propagacji błędów

1. Dla zbioru danych  $(Y_{pq}, X_{rq})$  dokonaj propagacji naprzód (z ang. *forward propagation*) sieci MLP i zapamiętaj wartości  $Y_{bj}^{h-1}$  oraz  $L_{ij}^h$ .
2. Wyznacz rekurencyjnie i zapamiętaj wartości  $\Delta_{ij}^h$  korzystając ze wzorów (etap *backpropagation*)

$$\boxed{\Delta_{ij}^{H+1} = \frac{\partial J}{\partial F_{ij}}, \quad \Delta_{ij}^h = \Delta_{kj}^{h+1} W_{ki}^{h+1} \sigma'(L_{ij}^h)}.$$

3. Wyznacz wartości pochodnych funkcji kosztu po parametrach sieci korzystając z

$$\boxed{\frac{\partial J}{\partial W_{ab}^h} = \Delta_{aj}^h Y_{bj}^{h-1}, \quad \frac{\partial J}{\partial B_a^h} = \Delta_{aj}^h I_j},$$

pamiętając, iż  $Y^0 = X$ .

Obliczmy jeszcze pochodne  $\partial J / \partial F_{ab}$  dla problemów regresji i klasyfikacji. W przypadku regresji sprawa jest prosta

$$J = \frac{1}{2} (F_{ij} - Y_{ij})^2$$

$$\frac{\partial J}{\partial F_{ab}} = (F_{ij} - Y_{ij}) \delta_{ai} \delta_{bj} = F_{ab} - Y_{ab}.$$

W przypadku entropii krzyżowej rachunki są trochę bardziej zawile:

$$J = -T_{ik} \log \Pi_{ik}, \quad \Pi_{ik} = \frac{\exp F_{ik}}{I_j \exp F_{jk}},$$

$$\frac{\partial J}{\partial F_{ab}} = \frac{\partial J}{\partial \Pi_{cd}} \frac{\partial \Pi_{cd}}{\partial F_{ab}},$$

dalej

$$\frac{\partial J}{\partial \Pi_{cd}} = -\frac{T_{ik}}{\Pi_{ik}} \delta_{ic} \delta_{kd} = -\frac{T_{cd}}{\Pi_{cd}}$$

oraz

$$\begin{aligned} \frac{\partial \Pi_{cd}}{\partial F_{ab}} &= \frac{\exp(F_{cd}) \delta_{ac} \delta_{bd} I_j \exp(F_{jd}) - \exp(F_{cd}) I_j \exp(F_{jd}) \delta_{aj} \delta_{bd}}{[I_j \exp(F_{jd})]^2} \\ &= \frac{\exp(F_{cd}) \delta_{ac} \delta_{bd}}{I_j \exp(F_{jd})} - \frac{\exp(F_{cd}) I_a \exp(F_{ad}) \delta_{bd}}{[I_j \exp(F_{jd})]^2}, \end{aligned}$$

skąd

$$\begin{aligned} \frac{\partial J}{\partial F_{ab}} &= -\frac{T_{cd}}{\Pi_{cd}} \frac{\exp(F_{cd}) \delta_{ac} \delta_{bd}}{I_j \exp(F_{jd})} + \frac{T_{cd}}{\Pi_{cd}} \frac{\exp(F_{cd}) I_a \exp(F_{ad}) \delta_{bd}}{[I_j \exp(F_{jd})]^2} \\ &= -\frac{T_{ab}}{\Pi_{ab}} \frac{\exp F_{ab}}{I_j \exp F_{jb}} + \frac{T_{cb}}{\Pi_{cb}} \frac{I_a \exp(F_{cb}) \exp(F_{ab})}{[I_j \exp(F_{jb})]^2} \\ &= -\frac{T_{ab}}{\Pi_{ab}} \Pi_{ab} + \frac{T_{cb}}{\Pi_{cb}} I_a \Pi_{cb} \Pi_{ab} \\ &= -T_{ab} I_{ab} + T_{cb} I_{cb} I_a \Pi_{ab} \end{aligned}$$

ale z definicji  $T$  mamy, iż  $\sum_c T_{cb} I_{cb} = I_b$ , gdyż dla danego przykładu  $b$  dokładne jedna klasa  $c$  jest poprawna

$$\frac{\partial J}{\partial F_{ab}} = -T_{ab} I_{ab} + I_a I_b \Pi_{ab} = \Pi_{ab} - T_{ab}.$$

### 3.5 Automatyczne różniczkowanie

### 3.6 Metody optymalizacji numerycznej

Mając algorytm efektywnego obliczania pochodnych funkcji kosztu, funkcję minimalizujemy korzystając z algorytmu spadku wzdłuż gradientu. W przypadku sieci neuronowych funkcja kosztu nie jest funkcją ściśle wypukłą, więc algorytm spadku wzdłuż gradientu nie znajdzie globalnego minimum; możemy liczyć jedynie na znalezienie minimum lokalnego.

### Algorytm MBGD

1. Zainicjuj parametry  $W_{ab}^h, B_a^h$  niewielkimi wartościami losowymi.
2. Podziel dane treningowe na  $K$  rozłącznych mini-batchy  $D_1, \dots, D_K$  jednakowej wielkości.
3. Powtarzaj przez  $N$  epok:  
Dla każdego mini-batcha  $D$ :
  - (a) Oblicz pochodne funkcji kosztu  $J$  po parametrach sieci korzystając z algorytmu wstecznej propagacji błędów.
  - (b) Zaktualizuj wartości parametrów zgodnie z:

$$\begin{aligned} W_{ab}^h &\leftarrow W_{ab}^h - \frac{\epsilon}{|D|} \frac{\partial J}{\partial W_{ab}^h} \\ B_a^h &\leftarrow B_a^h - \frac{\epsilon}{|D|} \frac{\partial J}{\partial B_a^h} \end{aligned},$$

gdzie  $\epsilon$  jest hiperparametrem zwanym stałą uczącą (z ang. *learning rate*).

## 3.7 Regularyzacja i inicjalizacja

Sieci neuronowe są bardzo *pojemnymi* modelami, przez co są bardzo podatne na overfitting i nie generalizują się dobrze poza zbiór treningowy. Bardzo ważnym elementem budowy sieci neuronowych są więc metody regularyzacji.

### 1. Czynniki regularyzujące

Analogicznie jak w przypadku prostych modeli liniowych jedną z możliwości regularyzacji jest dodanie do funkcji kosztu  $J$  czynnika regularyzującego zawierającego odpowiednią sumę norm poszczególnych parametrów sieci

$$J^* = J + \frac{\lambda}{2} \sum_{h=1}^{H+1} \sum_{i,j} (W_{ij}^h)^2, \quad \text{regularyzacja L2}$$

$$J^* = J + \frac{\lambda}{2} \sum_{h=1}^{H+1} \sum_{i,j} |W_{ij}^h|, \quad \text{regularyzacja L1}$$

Różnica między regularyzacją L2 i L1 jest taka, że norma L2 „zachęca” sieć do wybierania małych wag, ale nie dokładnie będących 0, natomiast L1

zmniejsza wagi, ale w szczególności prowadzi do wag wynoszących dokładnie 0. W związku z tym waga L1 przeprowadza selekcję cech - “wyłączy” te, które są mało ważne.

## 2. Early stopping

Innym prostym, lecz efektywnym podejściem do regularyzacji sieci neuronowych jest procedura *early stopping*. Polega ona na zatrzymaniu procesu uczenia (optymalizacji funkcji kosztu) w momencie, w którym wartość funkcji kosztu na wydzielonym ze zbioru treningowego zbiorze walidacyjnym zaczyna rosnąć (lub nie spada przez odpowiednio długi czas). Unikamy w ten sposób przeuczenia modelu. Takie podejście wymaga jednak dość dużego zbioru danych, z których musimy wydzielić trzy zbiory: zbiór treningowy (na którym uczymy model), zbiór walidacyjny (na którym ewaluujemy model przy procedurze *early stoppingu*) oraz zbiór testowy (na którym ewaluujemy model po treningu). Okres, przez który czekamy na uzyskanie lepszego wyniku, to cierpliwość (z ang. *patience*). Im mniejsze, tym mocniejszy jest ten rodzaj regularyzacji, ale trzeba z tym uważać, bo łatwo jest przesadzić i zbyt szybko przerywać trening. Niektóre implementacje uwzględniają tzw. *grace period*, czyli gwarantowaną minimalną liczbę epok, przez którą będziemy trenować sieć, niezależnie od wybranej cierpliwości.

## 3. Dropout

Bardzo popularną i szeroko stosowaną metodą regularyzacji sieci neuronowych jest dropout polegający na tym, iż w procesie treningu ze z góry zadany prawdopodobieństwem „wyłączamy” wyjście neuronu (tj. dla każdej aktualizacji wartości parametrów sieci, w algorytmie wstecznej propagacji błędu mnożymy wyjście  $Y_{ab}^h$  przez tensor  $P_{ab}^h$ , którego każdy element może być równy 0 z p-stwem  $p$  lub 1 z p-stwem  $1 - p$ ). Mechanizmu dropoutu używamy tylko w procesie treningu. W przypadku inferencji wyjście neuronu jest z kolei mnożone przez następujący stosunek

$$1 - \frac{\text{\#wyłączeń neuronu}}{\text{\#liczba aktualizacji parametrów sieci}}.$$

Typowo usuwa się dość sporo neuronów w warstwach ukrytych, np. 50%. Dzięki dropoutowi można używać z nim dość dużych stałych uczących oraz współczynników pędu, a także trenować znacznie większe i głębsze sieci. Okazuje się, iż w praktyce takie duże, mocno trenowane sieci z regularyzacją uczą się lepiej niż mniejsze, które by tej regularyzacji nie potrzebowały.

## 4. Połączenia rezydualne

Sporym problemem w procesie uczenia sieci neuronowych jest fakt, iż funkcja kosztu  $J$  nie jest wypukła, a dodatkowo często nie jest dość regularna

tj. pojawiają się tzw. „poszarpania” (z ang. *shattered*), które powodują problemy z obliczaniem gradientu. Metodą, która pozwala do pewnego stopnia wyeliminować ten problem jest wprowadzenie w sieci połączeń rezydualnych tj. warstw, których wyjście jest dane przez

$$Y^h : \mathbb{T}_{N,D} \mapsto \mathbb{T}_{N,D}$$

$$Y_{ik}^h(X) = \sigma(W_{ij}^h X_{jk} + B_i^h I_k) + X_{ik} \quad .$$

Oczywiście wprowadzenie takiej warstwy oznacza, iż liczba neuronów w następnej warstwie musi być taka sama.

#### 5. Data augmentation

Metoda data augmentation polega na dodaniu do zbioru treningowego replik przykładów z tego zbioru poddanych pewnym transformacjom względem których oczekujemy, iż odpowiedzi sieci będą niezmiennicze.

### 3.8 Sieci konwolucyjne (CNN)

### 3.9 Mechanizmy uwagi

## 4 Reinforcement learning i teoria optymalnego sterowania